BỘ GIÁO DỤC VÀ ĐÀO TẠO **BỘ NÔNG NGHIỆP VÀ PTNT**

TRƯỜNG ĐẠI HỌC THỦY LỢI



PHAN HUY NGUYÊN

DỰ ĐOÁN CHẤT LƯỢNG NƯỚC SỬ DỤNG HỌC MÁY

ĐỒ ÁN TỐT NGHIỆP

HÀ NỘI, NĂM 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO **BỘ NÔNG NGHIỆP VÀ PTNT**

TRƯỜNG ĐẠI HỌC THỦY LỢI

PHAN HUY NGUYÊN

DỰ ĐOÁN CHẤT LƯỢNG NƯỚC SỬ DỤNG HỌC MÁY

Ngành: Công nghệ thông tin

Mã số: 7480201

NGƯỜI HƯỚNG DẪN 1. Ths Nguyễn Thị Phương Thảo

HÀ NỘI, NĂM 2025

GÁY BÌA ĐỒ ÁN TỐT NGHIỆP, KHÓA LUẬN TỐT NGHIỆP

PHAN HUY NGUYÊN

ĐỒ ÁN TỐT NGHIỆP

HÀ NỘI, NĂM 2025

CỘNG HOÀ XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập - Tự do - Hạnh phúc

---------★---------

NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Họ tên sinh viên: Phan Huy Nguyên Hệ đào tạo : Đại học chính quy

Lớp: 60TH2 Ngành: Công nghệ thông tin

Khoa: Công nghệ thông tin

1- TÊN ĐỀ TÀI:

DỰ ĐOÁN CHẤT LƯỢNG NƯỚC SỬ DỤNG HỌC MÁY

2- CÁC TÀI LIỆU CƠ BẢN:

[1] "Quyết định số: QĐ 1460/QĐ-TCMT Ban hành ngày 12 tháng 11 năm 2019 về Hướng dẫn kỹ thuật tính toán và công bố chỉ số chất lượng nước của Việt Nam (VN_WQI)," 2019.

[2] Bui Tien Tung, "Gradient Boosting - Tất tần tật về thuật toán mạnh mẽ nhất trong Machine Learning," [Online]. Available: https://viblo.asia/p/gradient-boosting-tat-tan-tat-ve-thuat-toan-manh-me-nhat-trong-machine-learning-YWOZrN7vZQ0. [Accessed 9 9 2024].

[3] GeeksforGeeks, "Random Forest Algorithm in Machine Learning," [Online]. Available: https://www.geeksforgeeks.org/random-forest-algorithm-in-machine-learning. [Accessed 10 9 2024].

[4] Bui Quoc Lap, Thi-Thu-Hong Phan, Huu Du Nguyen, Le Xuan Quang, Phi Thi Hang, Nguyen Quang Phi, Vinh Truong Hoang, Pham Gia Linh, Bui Thi Thanh Hang, "Predicting Water Quality Index (WQI) by feature selection and machine learning: A case study of An Kim Hai irrigation system," 2023. [Online]. Available: https://www.sciencedirect.com/science/article/abs/pii/S1574954123000201?via%3Dihub. [Accessed 9 9 2024].

[5] L. BREIMAN, "Random Forests," 2001. [Online]. Available: https://link.springer.com/article/10.1023/A:1010933404324. [Accessed 10 9 2024].

[6] Nguyễn Đức Phong, Hà Hải Dương, "Nghiên cứu ứng dụng các mô hình học máy để dự báo chỉ số chất lượng nước mặt vùng bán đảo Cà Mau," 2023.

[7] Md Galal Uddin, Stephen Nash, Azizur Rahman, Agnieszka I. Olbert , "A sophisticated model for rating water quality," 10 4 2023. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0048969723002292. [Accessed 13 9 2024].

[8] Trevor Hastie , Robert Tibshirani , Jerome Friedman, "The Elements of Statistical Learning," 2009. [Online]. Available: https://www.sas.upenn.edu/~fdiebold/NoHesitations/BookAdvanced.pdf. [Accessed 15 9 2024].

[9] Huỳnh Phú, , Trần Thị Minh Hà, Nguyễn Thị Huệ, "Nghiên cứu đánh giá chất lượng nước các sông chính tỉnh Bình Thuận và đề xuất các giải pháp tiền đề bảo vệ nguồn nước," Tạp chí Khí tượng Thuỷ văn, 2024.

3- NỘI DUNG CÁC PHẦN THUYẾT MINH VÀ TÍNH TOÁN:

Nội dung các phần	Tỉ lệ %
Chương 1: Mở đầu	10%
Chương 2: Cơ sở lý thuyết • Tìm hiểu về học máy • Tìm hiểu các phương pháp phân tích và xử lý dữ liệu • Tìm hiểu về bài toán hồi quy và phương pháp đánh giá mô hình	45%
Chương 3: Mô hình giải quyết bài toán • Mô tả bài toán • Các công cụ thực nghiệm • Mô hình thực nghiệm	45%

4- GIÁO VIÊN HƯỚNG DẪN TỪNG PHẦN

Phần	Họ và tên giáo viên hướng dẫn
Chương 1: Mở đầu	Ths. Nguyễn Thị Phương Thảo
Chương 2: Cơ sở lý thuyết	
Chương 3: Mô hình giải quyết bài toán	

5- NGÀY GIAO NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Ngày .... tháng …. năm ….

Trưởng Bộ môn	**Giáo viên hướng dẫn chính**
(Ký và ghi rõ Họ tên)	*(Ký và ghi rõ Họ tên)*

Nhiệm vụ Đồ án tốt nghiệp đã được Hội đồng thi tốt nghiệp của Khoa thông qua.

Ngày …. tháng …. năm …..

Chủ tịch Hội đồng

(Ký và ghi rõ Họ tên)

Sinh viên đã hoàn thành và nộp bản Đồ án tốt nghiệp cho Hội đồng thi.

Ngày .... tháng …. năm …..

Sinh viên làm Đồ án tốt nghiệp

(Ký và ghi rõ Họ tên)

TRƯỜNG ĐẠI HỌC THUỶ LỢI
KHOA CÔNG NGHỆ THÔNG TIN

BẢN TÓM TẮT ĐỀ CƯƠNG ĐỒ ÁN TỐT NGHIỆP

TÊN ĐỀ TÀI: DỰ ĐOÁN CHẤT LƯỢNG NƯỚC SỬ DỤNG HỌC MÁY

Sinh viên thực hiện: PHAN HUY NGUYÊN
Lớp: 60TH2
Mã sinh viên: 1851061560
Số điện thoại: 0965524721
Email: 185106560@e.tlu.edu.vn
Giáo viên hướng dẫn: Ths Nguyễn Thị Phương Thảo

TÓM TẮT ĐỀ TÀI

Trong bối cảnh ô nhiễm nguồn nước ngày càng nghiêm trọng, chất lượng nước mặt tại khu vực trên Sông Sài Gòn và các rạch đổ ra sông Sài Gòn, cùng với Sông Đồng Nai và các rạch đổ ra sông Đồng Nai đã trở thành một vấn đề cấp bách cần được giải quyết. Khu vực này đang đối mặt với tình trạng ô nhiễm nặng nề do sự xả thải không kiểm soát từ các hoạt động công nghiệp và sinh hoạt. Điều này không chỉ ảnh hưởng đến sức khỏe của cộng đồng mà còn tác động tiêu cực đến hệ sinh thái và sự phát triển bền vững của khu vực. Trong bối cảnh đó, việc ứng dụng các mô hình học máy để dự đoán chỉ số chất lượng nước (WQI) trở nên cần thiết hơn bao giờ hết. Từ đó giúp các nhà nghiên cứu có thêm một công cụ để dự đoán mức độ ô nhiễm nước hiện tại và đưa ra một số giải pháp giúp giảm thiểu vấn đề này. Bài toán này được thực hiện với bộ dữ liệu về chỉ số nước biển tại khu vực trên Sông Sài Gòn và các rạch đổ ra sông Sài Gòn, cùng với Sông Đồng Nai và các rạch đổ ra sông Đồng Nai. Dữ liệu bao gồm các thông số: NH4+_N, NO2-_N, Nhiệt độ, pH, COD, DO, Coliform.

Đề tài này sẽ tập trung vào việc áp dụng hai mô hình học máy là Random Forest**,** Hồi quy tuyến tính (Linear Regression), Gradient Boosting để dự đoán mức độ ô nhiễm nước, giúp cải thiện chất lượng cuộc sống của cộng đồng.

Với đề tài: “Dự đoán chất lượng nước sử dụng học máy”, em mong muốn tìm hiểu, cài đặt được một phương pháp có thể dự báo được mức độ ô nhiễm nguồn nước, giúp cải thiện chất lượng cuộc sống của con người.

CÁC MỤC TIÊU CHÍNH

- Tìm hiểu bài toán dự đoán chất lượng nước mặt: Khảo sát và phân tích các yếu tố ảnh hưởng đến chất lượng nước, thu thập và làm sạch dữ liệu.
- Tìm hiểu và nghiên cứu các mô hình học máy: Tập trung vào ba mô hình Random Forest, Hồi quy tuyến tính và Gradient Boosting.
- Giải quyết bài toán nghiệp vụ: Xây dựng mô hình dự đoán chỉ số WQI dựa trên bộ dữ liệu đã thu thập.
- Áp dụng các mô hình học máy dự báo mức độ ô nhiễm nước mặt: Đánh giá và so sánh ba mô hình để tìm ra phương pháp hiệu quả nhất.
- Đánh giá mô hình: Sử dụng các chỉ số đánh giá độ chính xác như MSE, RMSE, MAE, và R-squared.
- Kết luận: Đưa ra kết quả và khuyến nghị để sử dụng mô hình dự đoán trong thực tế.

Mô hình học máy áp dụng

1. Random Forest (Random Forest):

Mô hình này sử dụng nhiều cây quyết định (decision trees) để xây dựng một "rừng" các cây nhằm cải thiện độ chính xác của dự đoán. Random Forest có khả năng xử lý dữ liệu phức tạp và nhiều thuộc tính, giúp tạo ra dự báo đáng tin cậy về chỉ số chất lượng nước.

- Ưu điểm: Giảm thiểu nguy cơ overfitting, xử lý tốt dữ liệu nhiều chiều.
- Nhược điểm: Khó diễn giải kết quả, yêu cầu tài nguyên tính toán cao.

2. Hồi quy tuyến tính (Linear Regression):

Là mô hình cơ bản và dễ hiểu, sử dụng để thiết lập mối quan hệ tuyến tính giữa các thông số như nhiệt độ, pH và chỉ số WQI. Mô hình này phù hợp để so sánh với các mô hình phức tạp hơn.

- Ưu điểm: Dễ triển khai và giải thích kết quả, phù hợp với các bài toán tuyến tính đơn giản.

- Nhược điểm: Hiệu quả kém khi dữ liệu có mối quan hệ phi tuyến tính.

3. Gradient Boosting:

Là một phương pháp học máy mạnh mẽ, sử dụng kỹ thuật tăng cường để xây dựng một mô hình dự đoán từ nhiều cây quyết định nhỏ (weak learners). Gradient Boosting thường được sử dụng để giải quyết các bài toán hồi quy và phân loại nhờ khả năng xử lý tốt dữ liệu phi tuyến tính và các mối quan hệ phức tạp.

- Ưu điểm: Hiệu suất cao trên nhiều loại dữ liệu, khả năng xử lý các mối quan hệ phi tuyến tính, hỗ trợ điều chỉnh linh hoạt thông qua các tham số như số lượng cây và tốc độ học.
- Nhược điểm: Thời gian huấn luyện lâu với tập dữ liệu lớn, khó giải thích so với các mô hình đơn giản, và dễ bị overfitting nếu không điều chỉnh tốt các tham số.

KẾT QUẢ DỰ KIẾN

- Hoàn thành các mục tiêu đề ra
- Hiểu và áp dụng xây dựng được mô hình học máy cho bài toán dự đoán chất lượng nước
- Báo cáo tổng kết ĐATN

LỜI CAM ĐOAN

Em xin cam đoan đây là Đồ án tốt nghiệp của bản thân em. Các kết quả trong Đồ án tốt nghiệp này là trung thực, và không sao chép từ bất kỳ một nguồn nào và dưới bất kỳ hình thức nào. Việc tham khảo các nguồn tài liệu (nếu có) đã được thực hiện trích dẫn và ghi nguồn tài liệu tham khảo đúng quy định.

Tác giả ĐATN

Phan Huy Nguyên

LỜI CÁM ƠN

Trong quá trình thực hiện đồ án tốt nghiệp, em đã nhận được rất nhiều sự giúp đỡ từ các thầy cô, nhận được sự cảm thông, động viên, sẻ chia từ gia đình, giúp em có điều kiện tập trung nghiên cứu và hoàn thiện đồ án tốt nghiệp sau hơn 4 năm dưới mái trường Đại học Thuỷ Lợi.

Em xin trân trọng cám ơn Ths Nguyễn Thị Phương Thảo và PGS. TS. Nguyễn Thị Thế Nguyên đã đóng góp ý kiến cho việc soạn thảo tài liệu Đồ án tốt nghiệp này. Nhờ sự hỗ trợ nhiệt tình, sự chỉ bảo tận tình và những lời khuyên thiết thực của các Cô đã giúp em rất nhiều trong việc hoàn thiện nội dung và phương pháp nghiên cứu. Sự nhiệt tình không quản công sức của các cô là tiền đề để em mạnh dạn đặt ra câu hỏi khi nghiên cứu, từng bước hoàn thiện đồ án. Em vô cùng biết ơn và trân trọng những đóng góp đó.

Bên cạnh đó, em xin bày tỏ lòng biết ơn sâu sắc tới tập thể cán bộ và quý thầy cô Trường Đại học Thủy Lợi nói chung, đặc biệt là các thầy cô của Khoa Công nghệ Thông tin. Sự hướng dẫn tận tâm, những bài giảng đầy nhiệt huyết cùng một nền tảng kiến thức vững chắc mà các thầy cô đã truyền đạt chính là bệ phóng quan trọng giúp em có thể hoàn thành đồ án tốt nghiệp ngày hôm nay.

Đồng thời, em cũng xin gửi lời cảm ơn chân thành tới gia đình và bạn bè – những người luôn bên cạnh, động viên và tiếp thêm sức mạnh cho em trong suốt hành trình học tập dưới mái trường Đại học Thủy Lợi. Sự ủng hộ và chia sẻ của mọi người chính là nguồn động lực lớn lao giúp em vượt qua những thử thách, khó khăn trong quá trình thực hiện đồ án này.

Tuy nhiên, em nhận thức rõ rằng với sự hạn chế về kinh nghiệm và kiến thức, đồ án tốt nghiệp của em không thể tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp quý báu từ thầy cô và hội đồng bảo vệ để em có thể hoàn thiện hơn. Đây sẽ là hành trang kinh nghiệm giá trị, giúp em tự tin bước vào công việc và định hướng rõ ràng hơn cho tương lai phía trước.

Em xin chân thành cảm ơn!

MỤC LỤC

DANH MỤC CÁC HÌNH ẢNH....1
DANH MỤC BẢNG BIỂU....2
MỞ ĐẦU....3
CHƯƠNG 1: GIỚI THIỆU BÀI TOÁN....4
1.1 Lý do chọn đề tài....4
1.2 Mục tiêu....5
1.3 Phạm vi, đối tượng nghiên cứu....6
1.3.1 Phạm vi....6
1.3.2 Khu vực nghiên cứu....7
CHƯƠNG 2: CÁC KỸ THUẬT DÙNG TRONG BÀI TOÁN....8
2.1 Tổng quan về học máy....8
2.1.1 Giới thiệu....8
2.1.2 Các thuật toán thông dụng....8
2.1.3 Ứng dụng của học máy trong các bài toán về môi trường....10
2.2 Mô hình trong bài toán....11
2.2.1 Hồi quy tuyến tính....11
2.2.2 Random Forest (Rừng ngẫu nhiên)....12
2.2.3 Gradient Boosting....13
2.3 Một số kỹ thuật phân tích và tiền xử lý dữ liệu....14
2.3.1 Kỹ thuật phân tích dữ liệu....14
2.3.2 Kỹ thuật tiền xử lý dữ liệu....15
2.4 Đánh giá mô hình....16
CHƯƠNG 3: ỨNG DỤNG PHƯƠNG PHÁP VÀ XÂY DỰNG MÔ HÌNH....17
3.1 Mô tả bài toán....17
3.1.1 Giới thiệu bài toán và bộ dữ liệu....17
3.1.2 Quy trình thực nghiệm....19
3.2 Các công cụ, thư viện dùng xây dựng....21
3.2.1 Các khung phần mềm học máy, học sâu....21
3.2.2 Các thư viện sử dụng....24
3.2.3 Các công nghệ hỗ trợ....27

3.3 Các bước thực nghiệm 29
3.3.1 Phân tích và tiền xử lý dữ liệu 29
3.3.2 Chuẩn bị dữ liệu 37
3.3.3 Huấn luyện mô hình và tối ưu tham số 38
3.4 Triển khai thực nghiệm 42
3.4.1 Kết quả huấn luyện mô hình 42
3.4.2 Dự đoán cho tương lai 47
3.4.3 Đánh giá khả năng áp dụng thực tế của mô hình 48
KẾT LUẬN VÀ ĐỀ XUẤT HƯỚNG PHÁT TRIỂN 50
TÀI LIỆU THAM KHẢO 52

DANH MỤC CÁC HÌNH ẢNH

Hình 2.1 Các dạng Học máy.....8
Hình 2.2 Mô hình hồi quy 12
Hình 2.3 Mô hình Random Forest.....13
Hình 3.1 Biểu đồ phân phối NH4+_N.....29
Hình 3 2 Biểu đồ phân phối NO2-_N.....30
Hình 3.3 Biểu đồ phân phối Nhiệt độ.....30
Hình 3.4 Biểu đồ phân phối pH.....31
Hình 3.5 Biểu đồ phân phối COD 32
Hình 3.6 Biểu đồ phân phối DO.....32
Hình 3.7 Biểu đồ phân phối Coliform 33
Hình 3.8 Biểu đồ hộp cho các thông số chất lượng nước.....34
Hình 3.9 Biểu đồ So sánh Nhiệt độ và DO.....35
Hình 3.10 So sánh Giá trị thực tế và Giá trị Dự đoán 45
Hình 3.11 Sơ đồ chất ảnh hưởng của mô hình Stacking 46
Hình 3.12 Dự đoán WQI năm 2025 47

DANH MỤC BẢNG BIỂU

Bảng 3.1 Loại bỏ dữ liệu thiếu 36
Bảng 3.2 Chuyển đổi dữ liệu sang kiểu số 37
Bảng 3.3 Chia tập dữ liệu 37
Bảng 3.4 Huấn luyện mô hình 38
Bảng 3.5 Tối ưu tham số Random Forest 40
Bảng 3.6 Tối ưu tham số cho Gradient Boosting 41
Bảng 3.7 Stacking model với tham số tối ưu 42
Bảng 3.8 Kết quả huấn luyện mô hình 42
Bảng 3.9 Thống kê kết quả đánh giá các mô hình học máy dự báo chỉ số chất lượng nước 44

MỞ ĐẦU

Ô nhiễm môi trường, đặc biệt là ô nhiễm nguồn nước, đang trở thành một trong những thách thức lớn nhất mà nhiều quốc gia trên thế giới phải đối mặt. Ở Việt Nam, với sự phát triển nhanh chóng của công nghiệp và đô thị hóa, nhiều nguồn nước mặt đã bị ô nhiễm nghiêm trọng do xả thải không kiểm soát từ các nhà máy và khu dân cư. Tình trạng này không chỉ ảnh hưởng trực tiếp đến sức khỏe của cộng đồng dân cư gần nguồn nước mà còn tác động tiêu cực đến hệ sinh thái và sự phát triển bền vững của khu vực.

Với sự phát triển của khoa học dữ liệu và học máy, việc sử dụng các mô hình dự đoán để đánh giá chất lượng nước đã trở thành một phương pháp tiên tiến và hiệu quả. Những mô hình này không chỉ giúp dự đoán mức độ ô nhiễm hiện tại mà còn dự đoán xu hướng ô nhiễm trong tương lai, từ đó đưa ra các biện pháp phòng ngừa và kiểm soát kịp thời.

Đề tài "Dự đoán chất lượng nước sử dụng học máy" là một nghiên cứu ứng dụng các mô hình học máy để dự đoán chỉ số chất lượng nước (Water Quality Index - WQI) dựa trên dữ liệu thu thập được từ khu vực trên Sông Sài Gòn và các rạch đổ ra sông Sài Gòn, cùng với Sông Đồng Nai và các rạch đổ ra sông Đồng Nai. Bài toán này nhằm tìm ra phương pháp dự đoán mức độ ô nhiễm nước, giúp cải thiện chất lượng cuộc sống và bảo vệ môi trường.

CHƯƠNG 1: GIỚI THIỆU BÀI TOÁN

1.1 Lý do chọn đề tài

Vai trò quan trọng của chất lượng nước đối với đời sống và môi trường

Chất lượng nước đóng vai trò quan trọng đối với sức khỏe con người, hệ sinh thái, sản xuất, kinh tế - xã hội và ứng phó với biến đổi khí hậu. Nước sạch là yếu tố thiết yếu cho nhu cầu sinh hoạt hằng ngày như uống, nấu ăn, tắm rửa, vệ sinh, đồng thời giúp giảm nguy cơ mắc các bệnh nguy hiểm như tiêu chảy, viêm ruột, thương hàn. Đặc biệt, nước bị ô nhiễm có thể gây hại lâu dài đến sức khỏe, đặc biệt ở trẻ em, làm suy giảm sự phát triển thể chất và tinh thần. Ngoài ra, chất lượng nước quyết định sự tồn tại và phát triển của hệ sinh thái dưới nước. Ô nhiễm nước gây mất cân bằng sinh thái, giảm đa dạng sinh học, thậm chí dẫn đến hiện tượng phú dưỡng, làm ảnh hưởng nghiêm trọng đến chuỗi thức ăn tự nhiên và các ngành kinh tế như thủy sản và du lịch.

Trong lĩnh vực sản xuất, nước sạch là điều kiện cần thiết cho nông nghiệp và công nghiệp. Nước ô nhiễm không chỉ làm giảm năng suất cây trồng và chất lượng thực phẩm mà còn gây hỏng thiết bị, tăng chi phí sản xuất và xử lý. Đồng thời, nước sạch là yếu tố nền tảng để phát triển kinh tế và xã hội bền vững, tạo việc làm trong ngành du lịch, thủy sản và giảm chi phí y tế nhờ hạn chế bệnh tật. Ngoài ra, nước sạch còn đóng vai trò quan trọng trong ứng phó với biến đổi khí hậu, giảm thiểu tác động của các hiện tượng thời tiết cực đoan như lũ lụt và hạn hán, đồng thời tăng cường khả năng phục hồi của cộng đồng trước những biến đổi môi trường. Vì vậy, đảm bảo chất lượng nước không chỉ là nhiệm vụ nhằm bảo vệ sức khỏe và môi trường mà còn là nền tảng để phát triển bền vững và xây dựng một tương lai ổn định hơn.

Tầm quan trọng của việc giám sát và dự đoán chất lượng nước để đảm bảo an toàn

Giám sát và dự đoán chất lượng nước đóng vai trò quan trọng trong việc bảo vệ sức khỏe con người, môi trường và phát triển bền vững. Việc này giúp phát hiện sớm ô nhiễm, ngăn ngừa các bệnh nguy hiểm như tiêu chảy và ngộ độc, đồng thời bảo vệ hệ sinh thái thủy sinh. Dữ liệu thu thập được hỗ trợ quản lý tài nguyên nước hiệu quả, phục vụ quy hoạch đô thị, nông nghiệp và công nghiệp.

Ngoài ra, nó còn nâng cao nhận thức cộng đồng về bảo vệ nguồn nước và thúc đẩy nghiên cứu phát triển công nghệ xử lý nước. Trong bối cảnh biến đổi khí hậu, giám sát chất lượng nước giúp theo dõi các thay đổi và xây dựng chiến lược ứng phó hiệu quả. Tóm lại, đây là yếu tố then chốt để đảm bảo sức khỏe, bảo vệ môi trường và duy trì nguồn nước sạch cho các thế hệ tương lai.

Những thách thức trong việc phân tích dữ liệu nước theo cách truyền thống

Phân tích dữ liệu nước đóng vai trò quan trọng trong quản lý tài nguyên nước, bảo vệ môi trường và sức khỏe cộng đồng, nhưng các phương pháp truyền thống gặp nhiều thách thức. Việc thu thập dữ liệu thủ công tốn thời gian, chi phí cao, thiếu tính linh hoạt và khả năng phát hiện toàn diện các chất ô nhiễm. Ngoài ra, khối lượng dữ liệu lớn ngày càng gia tăng khiến các phương pháp truyền thống không đáp ứng hiệu quả.

Tại Việt Nam, đặc biệt ở khu vực khu vực trên Sông Sài Gòn và các rạch đổ ra sông Sài Gòn, cũng như trên Sông Đồng Nai và các rạch đổ ra sông Đồng Nai, ô nhiễm nước mặt do xả thải công nghiệp và sinh hoạt đang ở mức báo động, gây ra các bệnh nguy hiểm cho cộng đồng. Trước thực trạng này, việc áp dụng các công nghệ tiên tiến như học máy trong dự đoán và đánh giá chất lượng nước là cần thiết. Học máy tận dụng dữ liệu lớn để xây dựng mô hình dự báo, mang lại hiệu quả cao trong giám sát và quản lý nguồn nước, góp phần bảo vệ sức khỏe và môi trường.

1.2 Mục tiêu

Mục tiêu chính của đề tài này là phát triển một mô hình học máy có khả năng dự đoán chỉ số chất lượng nước WQI dựa trên các thông số môi trường thu thập được từ khu vực nghiên cứu. WQI là một chỉ số quan trọng được sử dụng để đánh giá chất lượng nước trong các hệ sinh thái tự nhiên cũng như trong các nguồn cung cấp nước cho con người. Việc dự đoán chính xác WQI có ý nghĩa thiết thực trong việc giám sát, quản lý tài nguyên nước, và hỗ trợ ra quyết định cho các cơ quan quản lý môi trường. Cụ thể, em sẽ áp dụng ba mô hình học máy chính là Random Forest (Random Forest), Hồi quy tuyến tính (Linear Regression) và Gradient Boosting để xây dựng các mô hình dự đoán.

1.3 Phạm vi, đối tượng nghiên cứu

1.3.1 Phạm vi

Dữ liệu nghiên cứu sẽ bao gồm một loạt các thông số môi trường quan trọng, cụ thể là nhiệt độ, pH, hàm lượng oxy hòa tan (DO), nồng độ Ammonium Nitrogen (NH4+_N), nồng độ Nitrite Nitrogen (NO2-_N), nhu cầu oxy hóa học (COD), và số lượng Coliform. Những thông số này được lựa chọn dựa trên khả năng chúng có thể phản ánh tình trạng ô nhiễm và sức khỏe của nguồn nước. Ví dụ, hàm lượng oxy hòa tan là chỉ số quan trọng cho sự sống của các loài thủy sinh, trong khi nồng độ các chất dinh dưỡng như Ammonium và Nitrite có thể chỉ ra mức độ ô nhiễm từ nước thải sinh hoạt và nông nghiệp. Số lượng Coliform cũng sẽ được xem xét để đánh giá sự hiện diện của vi khuẩn gây bệnh, từ đó đưa ra những cảnh báo về nguy cơ sức khỏe cho cộng đồng.

Phạm vi thời gian của nghiên cứu sẽ được giới hạn trong các dữ liệu thu thập từ năm 2023 đến 2024. Việc này cho phép nghiên cứu theo dõi các biến động về chất lượng nước trong khoảng thời gian ngắn, đồng thời giúp phân tích các yếu tố ảnh hưởng theo mùa, từ đó đưa ra dự đoán chính xác hơn về xu hướng ô nhiễm trong tương lai. Thông qua việc thu thập và phân tích các dữ liệu này, nghiên cứu không chỉ cung cấp cái nhìn tổng quan về tình trạng ô nhiễm nước mà còn giúp xác định các biện pháp can thiệp cần thiết nhằm cải thiện chất lượng nguồn nước trong khu vực.

Ngoài ra, kết quả nghiên cứu sẽ được sử dụng để phát triển các mô hình dự đoán, từ đó hỗ trợ việc ra quyết định trong quản lý tài nguyên nước. Những mô hình này có thể giúp các cơ quan chức năng xác định các khu vực có nguy cơ ô nhiễm cao, từ đó thực hiện các biện pháp kiểm soát và bảo vệ nguồn nước hiệu quả hơn. Việc nghiên cứu và dự đoán mức độ ô nhiễm nước sẽ góp phần quan trọng vào việc duy trì sự bền vững của nguồn nước, bảo vệ sức khỏe cộng đồng, và bảo tồn các hệ sinh thái thủy sinh trong khu vực Sông Sài Gòn và Sông Đồng Nai.

Đối tượng nghiên cứu của đề tài này là chất lượng nước tại khu vực trên Sông Sài Gòn và các rạch đổ ra sông Sài Gòn, cũng như trên Sông Đồng Nai và các rạch đổ ra sông Đồng Nai. Những dữ liệu này được thu thập từ tài liệu “Báo cáo quan trắc nước mặt tháng 1, tháng 2, tháng 3 năm 2024” do Trung tâm Quan trắc – Kỹ thuật Tài nguyên và

môi trường tỉnh Bình Dương cung cấp. Trong khuôn khổ nghiên cứu, em sẽ tập trung vào việc phân tích và đánh giá các chỉ số môi trường có ảnh hưởng trực tiếp đến chất lượng nước, bao gồm các thông số như độ pH, độ đục, nồng độ oxy hòa tan, và các chất ô nhiễm khác. Những yếu tố này không chỉ phản ánh tình trạng hiện tại của nguồn nước mà còn có thể dự đoán xu hướng thay đổi trong tương lai. Đặc biệt, từ việc phân tích các chỉ số này, em sẽ dự đoán chỉ số Chất lượng Nước (Water Quality Index - WQI), một chỉ số tổng hợp cho thấy mức độ ô nhiễm và khả năng sử dụng của nước.

1.3.2 Khu vực nghiên cứu

Khu vực trên Sông Sài Gòn và các rạch đổ ra sông Sài Gòn, cùng với Sông Đồng Nai và các rạch đổ ra sông Đồng Nai, là hai trong những khu vực có nguồn nước mặt bị ô nhiễm nghiêm trọng. Sự phát triển nhanh chóng của các khu công nghiệp, cùng với lượng xả thải từ các nhà máy, đã tạo ra áp lực lớn lên chất lượng nước tại đây. Những hoạt động này không chỉ làm suy giảm chất lượng nước mà còn ảnh hưởng đến sức khỏe của cộng đồng và hệ sinh thái.

Trong bối cảnh này, khu vực nghiên cứu sẽ bao gồm không chỉ các con sông lớn mà còn cả những hồ và rạch nhỏ trong vùng. Đây là những nơi chịu tác động trực tiếp từ cả hoạt động công nghiệp và sinh hoạt của người dân. Việc xả thải chưa qua xử lý hoặc xử lý không đạt tiêu chuẩn từ các nhà máy, cùng với rác thải sinh hoạt và hóa chất nông nghiệp, đã dẫn đến tình trạng ô nhiễm đáng lo ngại. Các chỉ số chất lượng nước như nồng độ oxy hòa tan, phốt pho, nitrat, và các vi sinh vật gây bệnh thường xuyên vượt ngưỡng cho phép, gây ảnh hưởng nghiêm trọng đến sự sống của các loài thủy sinh và sức khỏe của con người.

CHƯƠNG 2: CÁC KỸ THUẬT DÙNG TRONG BÀI TOÁN

2.1 Tổng quan về học máy

2.1.1 Giới thiệu

Học máy (Machine Learning) là một lĩnh vực con của trí tuệ nhân tạo, tập trung vào việc phát triển các thuật toán cho phép máy tính tự học và cải thiện hiệu suất từ dữ liệu mà không cần lập trình cụ thể. Học máy được phân loại thành ba loại chính:

- Học có giám sát (Supervised Learning): Mô hình học từ dữ liệu đã được gán nhãn, tức là mỗi mẫu dữ liệu đều có nhãn tương ứng. Mục tiêu là học một hàm ánh xạ từ đầu vào đến đầu ra dựa trên dữ liệu huấn luyện.
- Học không giám sát (Unsupervised Learning): Mô hình học từ dữ liệu không có nhãn, nhằm phát hiện các cấu trúc hoặc mẫu ẩn trong dữ liệu. Các kỹ thuật phổ biến bao gồm phân cụm (clustering) và giảm chiều dữ liệu (dimensionality reduction).
- Học tăng cường (Reinforcement Learning): Mô hình học thông qua tương tác với môi trường, nhận phản hồi dưới dạng phần thưởng hoặc hình phạt, từ đó học cách tối ưu hóa hành động để đạt được mục tiêu.



Hình 2.1 Các dạng Học máy

2.1.2 Các thuật toán thông dụng

Học có giám sát là một phương pháp học máy trong đó mô hình được huấn luyện trên một tập dữ liệu đã biết trước cả đầu vào (features) và đầu ra (labels). Một số thuật toán phổ biến trong học có giám sát bao gồm hồi quy tuyến tính, hồi quy logistic, cây quyết định, Random Forest, máy hỗ trợ véc-tơ, gradient boosting và K-Nearest Neighbors (KNN). Hồi quy tuyến tính là mô hình dự đoán giá trị liên tục bằng cách tìm kiếm mối

quan hệ tuyến tính giữa biến độc lập và biến phụ thuộc, trong khi hồi quy logistic là mô hình phân loại nhị phân, dự đoán xác suất của một sự kiện xảy ra. Cây quyết định sử dụng cấu trúc dạng cây để phân loại hoặc dự đoán giá trị liên tục thông qua việc phân chia dữ liệu theo các đặc trưng, còn Random Forest là tập hợp của nhiều cây quyết định, giúp cải thiện độ chính xác và giảm nguy cơ overfitting. Máy hỗ trợ véc-tơ (SVM) tìm kiếm một siêu phẳng tối ưu để phân chia các lớp dữ liệu, đặc biệt hiệu quả trên các tập dữ liệu nhỏ và có biên phân cách rõ ràng. Gradient boosting sử dụng kỹ thuật tăng cường để tập hợp nhiều cây quyết định nhỏ, tối ưu hóa hiệu suất trên các bài toán phi tuyến tính và dữ liệu phức tạp. Cuối cùng, KNN là một thuật toán dựa trên khoảng cách giữa các điểm dữ liệu, hiệu quả với tập dữ liệu nhỏ nhưng dễ bị ảnh hưởng bởi nhiễu khi dữ liệu lớn. Các thuật toán này được áp dụng rộng rãi trong các lĩnh vực như tài chính, y tế, tiếp thị và khoa học dữ liệu để giải quyết các bài toán dự đoán và phân loại.

Học không giám sát là một phương pháp học máy trong đó mô hình được huấn luyện trên tập dữ liệu chỉ có đầu vào (features) mà không có nhãn (labels). Phương pháp này thường được sử dụng để khám phá cấu trúc tiềm ẩn trong dữ liệu hoặc giảm kích thước của dữ liệu để dễ xử lý hơn. Một trong những thuật toán phổ biến nhất là phân cụm K-means, phương pháp phân chia dữ liệu thành K nhóm dựa trên độ tương đồng giữa các điểm dữ liệu. K-means đặc biệt hiệu quả trong việc nhận diện các nhóm hoặc mẫu trong dữ liệu mà không cần sự can thiệp từ con người. Ngoài ra, kỹ thuật giảm chiều dữ liệu PCA (Principal Component Analysis) cũng được sử dụng rộng rãi để giảm số lượng biến trong tập dữ liệu bằng cách giữ lại các thành phần chính mang thông tin quan trọng nhất. PCA giúp đơn giản hóa dữ liệu, tăng tốc độ xử lý và giảm nguy cơ overfitting trong các bài toán phức tạp. Học không giám sát thường được áp dụng trong các lĩnh vực như phân tích thị trường, phát hiện bất thường, xử lý hình ảnh và nén dữ liệu.

Học tăng cường là một phương pháp học máy, trong đó một tác nhân (agent) học cách hành động trong môi trường bằng cách thử nghiệm và nhận phản hồi dưới dạng phần thưởng hoặc hình phạt. Phương pháp này tập trung vào việc tối ưu hóa chuỗi hành động để đạt được phần thưởng lớn nhất trong dài hạn. Một thuật toán nổi bật trong học tăng cường là Q-learning, một phương pháp không dựa trên mô hình, cho phép tác nhân học từ trải nghiệm mà không cần biết trước về động lực của môi trường. Q-learning sử dụng

bảng Q (Q-table) để lưu trữ giá trị kỳ vọng của mỗi hành động trong từng trạng thái, từ đó tối ưu hóa chiến lược hành động. Học tăng cường được áp dụng rộng rãi trong các lĩnh vực như trí tuệ nhân tạo trong trò chơi, điều khiển robot, và tối ưu hóa hệ thống, nơi việc học từ tương tác với môi trường là yếu tố quan trọng.

2.1.3 Ứng dụng của học máy trong các bài toán về môi trường

Học máy ngày càng trở thành một công cụ quan trọng trong nghiên cứu và quản lý môi trường. Với khả năng phân tích dữ liệu lớn và tìm ra các mẫu ẩn, học máy giúp chúng ta giải quyết nhiều vấn đề liên quan đến môi trường một cách hiệu quả và chính xác. Trong thời đại công nghệ phát triển, học máy đóng vai trò quan trọng trong việc dự báo, giám sát, và quản lý môi trường và tài nguyên thiên nhiên.

Học máy đã chứng minh khả năng vượt trội trong việc dự đoán chất lượng nước dựa trên các chỉ số như pH, độ dẫn điện, và hàm lượng oxy hòa tan. Các mô hình học máy không chỉ giúp phát hiện sớm các dấu hiệu của ô nhiễm mà còn cung cấp thông tin chi tiết và chính xác cho các cơ quan quản lý nước, từ đó hỗ trợ quá trình quản lý và bảo vệ nguồn nước hiệu quả hơn.

Bên cạnh đó, các thuật toán học máy hiện đại có khả năng phân tích dữ liệu đến từ các cảm biến không khí để giám sát mức độ ô nhiễm không khí. Nhờ vào khả năng dự đoán xu hướng ô nhiễm trong tương lai dựa trên dữ liệu lịch sử và thời tiết, học máy đóng vai trò quan trọng trong việc cảnh báo sớm về mức độ ô nhiễm, từ đó giúp các chính phủ và tổ chức xã hội đưa ra các biện pháp phòng ngừa và giảm thiểu ô nhiễm không khí.

Học máy không chỉ giúp phân tích hình ảnh vệ tinh và dữ liệu địa lý mà còn hỗ trợ trong việc phát hiện các thay đổi trong hệ sinh thái, bao gồm mất mát rừng, biến đổi đất đai, và sự thay đổi của các loài sinh vật. Việc này cung cấp cho các nhà quản lý môi trường và các tổ chức bảo vệ thiên nhiên những thông tin quan trọng để đưa ra các chiến lược bảo tồn và phục hồi môi trường hiệu quả.

Ngoài ra, học máy đóng vai trò quan trọng trong phát triển các mô hình dự báo thời tiết và biến đổi khí hậu. Cung cấp thông tin cần thiết cho nông nghiệp, quản lý nước và các lĩnh vực khác giúp cộng đồng chuẩn bị tốt hơn cho các hiện tượng thời tiết cực đoan.

Thêm vào đó, học máy phân tích dữ liệu liên quan đến tài nguyên thiên nhiên như nước, đất và khoáng sản để tối ưu hóa việc sử dụng và bảo vệ chúng. Giúp xác định các khu vực có tiềm năng cao cho phát triển bền vững và hỗ trợ trong việc lập kế hoạch sử dụng tài nguyên một cách hiệu quả.

Học máy cung cấp nhiều ứng dụng hữu ích trong các bài toán về môi trường, từ dự đoán chất lượng nước đến giám sát ô nhiễm không khí và quản lý tài nguyên thiên nhiên. Việc áp dụng công nghệ này không chỉ giúp nâng cao hiệu quả trong nghiên cứu và quản lý môi trường mà còn góp phần bảo vệ sức khỏe con người và hệ sinh thái. Hướng tới tương lai, sự phát triển của học máy hứa hẹn sẽ mở ra nhiều cơ hội mới trong việc giải quyết các thách thức môi trường toàn cầu.

2.2 Mô hình trong bài toán

Trong bài toán dự đoán chất lượng nước, biến mục tiêu thường là một chỉ số liên tục, chẳng hạn như Chỉ số Chất lượng Nước (WQI). Điều này khiến bài toán trở thành một bài toán hồi quy, trong đó mục tiêu là xây dựng một mô hình để dự đoán giá trị của WQI dựa trên các thông số đầu vào như nhiệt độ, độ sâu, nồng độ oxy hòa tan, và các yếu tố môi trường khác. Việc lựa chọn mô hình hồi quy phù hợp phụ thuộc vào tính chất của dữ liệu, yêu cầu về độ chính xác, tính dễ diễn giải, và khả năng xử lý dữ liệu phức tạp. Em chọn mô hình hồi quy tuyến tính, Random Forest và Gradient Boosting để dự đoán chất lượng nước, tùy theo tính chất dữ liệu và mục tiêu dự đoán. Hồi quy tuyến tính đơn giản, dễ hiểu, phù hợp với dữ liệu tuyến tính, nhưng gặp khó khăn với mối quan hệ phi tuyến và giá trị ngoại lệ. Trong khi đó, Random Forest và Gradient Boosting mạnh mẽ hơn, xử lý tốt dữ liệu nhiễu và mối quan hệ phức tạp, nhưng yêu cầu tài nguyên tính toán cao và khó diễn giải hơn.

2.2.1 Hồi quy tuyến tính

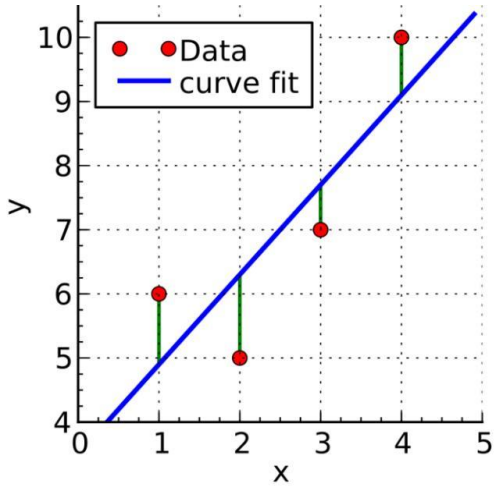
Hồi quy tuyến tính là một phương pháp thống kê để hồi quy dữ liệu với biến phụ thuộc có giá trị liên tục trong khi các biến độc lập có thể có một trong hai giá trị liên tục hoặc là giá trị phân loại. Trong phân tích dữ liệu và dự đoán, hồi quy tuyến tính đa biến là một phương pháp quan trọng để hiểu và dự đoán mối quan hệ giữa một biến phụ thuộc (WQI) và nhiều biến độc lập (Các chỉ số chất lượng nước). Mô hình hồi quy tuyến tính

đa biến cung cấp thông tin quan trọng về mức độ ảnh hưởng của mỗi biến độc lập đến biến phụ thuộc, cũng như mức độ toàn vẹn của mô hình dự đoán. Mô hình hồi quy tuyến tính đa biến mô tả mối quan hệ tuyến tính giữa một biến phụ thuộc (Y) và nhiều biến độc lập ($X_1, X_2, \dots, X_n$). Phương trình mô hình có dạng:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n + \epsilon \qquad (2\text{-}1)$$

Trong đó:

- Y là biến phụ thuộc (cũng được gọi là biến phản ứng hoặc biến dự đoán).
- $X_1, X_2, \dots, X_n$ là các biến độc lập (còn được gọi là các biến diễn giải hoặc biến giải thích).
- $\beta_1, \beta_2, \dots, \beta_n$ là các hệ số hồi quy, thể hiện mức độ tác động nhưng độc lập.

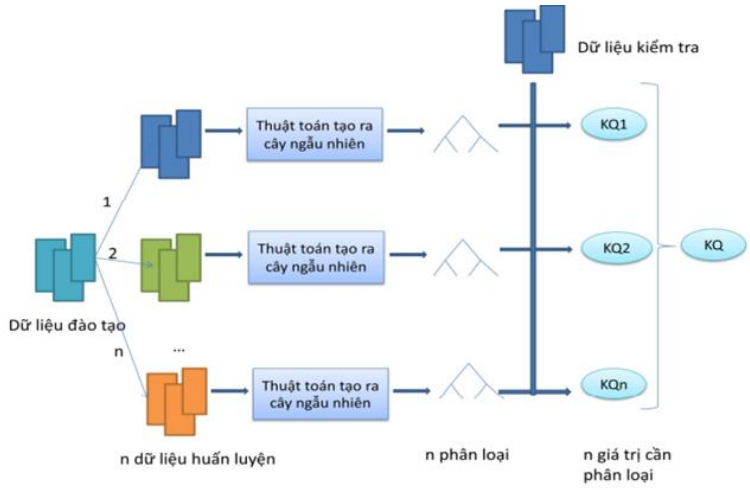


Hình 2.2 Mô hình hồi quy

2.2.2 Random Forest (Rừng ngẫu nhiên)

Random Forest là một thuật toán ensemble learning dựa trên cơ sở của cây quyết định. Nó xây dựng nhiều cây quyết định và kết hợp kết quả từ các cây này để đưa ra dự đoán cuối cùng. Random Forest thích hợp cho việc xử lý các tập dữ liệu lớn, có nhiều biến và không gian đặc trưng phức tạp. Trong nghiên cứu này, Random Forest có thể học được các mô hình phức tạp để dự báo chất lượng nước dựa trên các biến độc lập. Một số ưu điểm nổi bật của Random Forest bao gồm khả năng chống overfitting hiệu quả, độ chính xác cao và khả năng xử lý dữ liệu lớn. Tuy nhiên, nó cũng có nhược điểm như khó khăn trong việc giải thích kết quả và tốn tài nguyên tính toán. Random Forest

thường được ứng dụng trong các bài toán phân loại văn bản và dự đoán giá trị liên tục, làm cho nó trở thành một lựa chọn phổ biến trong lĩnh vực học máy.



Hình 2.3 Mô hình Random Forest

2.2.3 Gradient Boosting

Gradient Boosting là một thuật toán học máy thuộc nhóm học có giám sát (supervised learning), được sử dụng phổ biến trong các bài toán hồi quy (regression) và phân loại (classification). Thuật toán này hoạt động dựa trên ý tưởng tăng cường (boosting), trong đó các mô hình đơn giản như cây quyết định nhỏ được xây dựng tuần tự. Mỗi mô hình mới được tạo ra nhằm sửa chữa lỗi của các mô hình trước đó bằng cách tối ưu hóa hàm mất mát (loss function), thường sử dụng thuật toán tối ưu hóa theo gradient để xác định hướng điều chỉnh hiệu quả nhất. Với khả năng xử lý cả dữ liệu tuyến tính và phi tuyến tính, Gradient Boosting hoạt động hiệu quả trên dữ liệu phức tạp và hỗ trợ nhiều loại hàm mất mát khác nhau, chẳng hạn như hàm bình phương trung bình (mean squared error) cho hồi quy hoặc hàm log (log-loss) cho phân loại. Tuy nhiên, thuật toán yêu cầu điều chỉnh các siêu tham số như learning rate, số lượng cây (n_estimators), và độ sâu cây (max_depth) để đạt được hiệu suất tối ưu. Gradient Boosting thường được ứng dụng trong các lĩnh vực như tài chính, y tế và khoa học dữ liệu nhờ tính linh hoạt và khả năng dự đoán chính xác. Tuy nhiên, nó cũng nhạy cảm với dữ liệu nhiễu và thường mất nhiều thời gian tính toán hơn so với một số thuật toán khác như Random Forest.

2.3 Một số kỹ thuật phân tích và tiền xử lý dữ liệu

2.3.1 Kỹ thuật phân tích dữ liệu

Phân tích dữ liệu là quá trình khám phá, xử lý và rút trích thông tin từ dữ liệu để phục vụ việc giải quyết các bài toán cụ thể. Trong học máy, phân tích dữ liệu đóng vai trò quan trọng trong việc chuẩn bị, hiểu và xây dựng mô hình hiệu quả. Dưới đây là mô tả chi tiết về các kỹ thuật phân tích dữ liệu phổ biến.

- Phân tích dữ liệu mô tả (Descriptive Analysis): Tóm tắt và mô tả các đặc điểm chính của tập dữ liệu. Có nhiều phương pháp phân tích: thống kê cơ bản, trực quan hóa dữ liệu, tổng hợp dữ liệu, ...

- Phân tích khám phá dữ liệu (Exploratory Data Analysis – EDA: Khám phá các mẫu (patterns), mối quan hệ, và giá trị bất thường trong dữ liệu. Có nhiều phương pháp phân tích: phân tích tương quan, phát hiện ngoại lệ, trực quan hóa mối quan hệ, …

- Phân tích dự đoán (Predictive Analysis): Sử dụng dữ liệu hiện có để dự đoán kết quả tương lai. Có nhiều phương pháp phân tích như sau: hồi quy (Regression), phân loại (Classification), phân tích dữ liệu chuỗi thời gian, ...

- Phân tích chẩn đoán (Diagnostic Analysis): Xác định nguyên nhân của các mẫu hoặc hành vi trong dữ liệu. Có nhiều phương pháp: Sử dụng các thuật toán như Random Forest hoặc XGBoost để đánh giá tầm quan trọng của các biến, Sử dụng các kỹ thuật như k-means để nhóm các điểm dữ liệu tương tự nhau và tìm hiểu sự khác biệt giữa các cụm, Sử dụng các mô hình quan hệ nhân quả để tìm hiểu các yếu tố dẫn đến sự kiện cụ thể.

- Phân tích định chuẩn (Prescriptive Analysis): Đưa ra khuyến nghị hoặc giải pháp tối ưu dựa trên dữ liệu. Có nhiều phương pháp: Tối ưu hóa, học tăng cường, phân tích kịch bản, ...

- Phân tích giá trị bất thường (Anomaly Detection): Phát hiện các giá trị bất thường trong dữ liệu có thể đại diện cho lỗi hoặc sự kiện quan trọng. Có một số phương pháp: Sử dụng các mô hình như Isolation Forest, DBSCAN để tìm điểm bất thường. Dùng

z-score, độ lệch chuẩn, hoặc các mô hình thống kê khác. Mạng học sâu tự mã hóa để phát hiện mẫu bất thường.

- Phân tích cụm (Clustering Analysis): Phân nhóm dữ liệu dựa trên các đặc điểm tương tự. Có một số phương pháp: K-means Clustering, Hierarchical Clustering: Xây dựng cây phân cụm để hiểu quan hệ giữa các nhóm, DBSCAN: Phát hiện cụm dựa trên mật độ điểm dữ liệu.

- Phân tích nâng cao (Advanced Analytics): Áp dụng các mô hình phức tạp hoặc công nghệ mới nhất để phân tích dữ liệu. Có một số phương pháp: Deep Learning, Natural Language Processing, Graph Analysis.

2.3.2 Kỹ thuật tiền xử lý dữ liệu

Tiền xử lý dữ liệu là bước quan trọng trong quá trình xây dựng mô hình học máy, bao gồm một số kỹ thuật như sau:

- ***Làm sạch dữ liệu:***

- Xử lý giá trị thiếu: Là một bước quan trọng trong tiền xử lý dữ liệu khi làm việc với tập dữ liệu chứa các giá trị bị thiếu hoặc không đầy đủ. Giá trị thiếu có thể xảy ra do lỗi thu thập dữ liệu, lỗi lưu trữ, h`oặc các nguyên nhân khách quan khác. Sử dụng các phương pháp như loại bỏ mẫu có giá trị thiếu hoặc thay thế bằng giá trị trung bình, trung vị hoặc mode.

- Xử lý giá trị ngoại lai: Giá trị ngoại lai là những điểm dữ liệu nằm ngoài phạm vi bình thường, có thể do lỗi hoặc các trường hợp hiếm gặp. Để phát hiện, có thể dùng thống kê (IQR, Z-score), phân tích đồ họa (boxplot, scatter plot), hoặc thuật toán như Isolation Forest, DBSCAN. Xử lý ngoại lai bằng cách thay thế bằng trung bình, trung vị, giá trị cố định (ngưỡng), hoặc biến đổi dữ liệu như logarithm, căn bậc hai.

- ***Chuyển đổi dữ liệu:***

Chuyển đổi dữ liệu là một bước trong tiền xử lý dữ liệu nhằm thay đổi định dạng, thang đo hoặc cấu trúc của dữ liệu để phù hợp với yêu cầu của mô hình học máy hoặc phân

tích dữ liệu. Quá trình này giúp cải thiện hiệu suất mô hình, tăng độ chính xác và giảm ảnh hưởng của nhiễu hoặc giá trị bất thường.

Một số cách chuyển đổi:

- Từ chuỗi (string) sang số (numeric): Sử dụng các phương pháp như pd.to_numeric() trong Python để chuyển đổi cột chuỗi chứa số (như "123") thành kiểu số.
- Từ danh mục (categorical) sang số:

Sử dụng mã hóa như:

– Label Encoding: Gán một số nguyên cho từng danh mục.

– One-Hot Encoding: Biểu diễn mỗi danh mục dưới dạng vector nhị phân.

2.4 Đánh giá mô hình

Sử dụng các chỉ số như R-squared, Mean Squared Error (MSE) và Mean Absolute Error (MAE) để đánh giá độ chính xác của mô hình. Đánh giá mô hình học máy không chỉ dựa trên một chỉ số duy nhất mà cần kết hợp nhiều kỹ thuật và chỉ số phù hợp với bài toán cụ thể. Việc hiểu rõ các kỹ thuật này sẽ giúp đảm bảo mô hình đạt được hiệu suất tối ưu và có thể áp dụng hiệu quả trong thực tế.

- Mean Squared Error (MSE): Trung bình bình phương sai số giữa giá trị dự đoán và giá trị thực tế. MSE càng nhỏ cho thấy mô hình dự đoán chính xác hơn.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \qquad (2\text{-}1)$$

- Root Mean Squared Error (RMSE): RMSE (Root Mean Squared Error) là căn bậc hai của MSE. Nó cho biết sai số trung bình của các dự đoán, giúp đưa các sai số về cùng đơn vị với dữ liệu, giúp việc giải thích dễ dàng hơn.

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \qquad (2\text{-}2)$$

- R-squared: Đo lường tỷ lệ biến thiên của biến phụ thuộc được giải thích bởi mô hình. Giá trị R-squared nằm trong khoảng từ 0 đến 1, với giá trị càng cao cho thấy mô hình giải thích tốt hơn biến thiên của dữ liệu.

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \quad (2\text{-}3)$$

- Mean Absolute Error (MAE): Trung bình giá trị tuyệt đối của sai số giữa giá trị dự đoán và giá trị thực tế. MAE cung cấp thông tin về độ lệch trung bình của dự đoán so với thực tế.

$$MAE = \frac{1}{n}\sum_{i=1}^{n} | y_i - \hat{y}_i | \quad (2\text{-}4)$$

Trong đó:

n : Tổng số lượng mẫu trong tập dữ liệu.

y_i: Giá trị thực tế (observed value) của mẫu thứ i.

$\hat{y}_i$: Giá trị dự đoán (predicted value) của mẫu thứ i.

Sự cần thiết của việc đánh giá mô hình:

- Đảm bảo tính chính xác của mô hình.
- Đảm bảo mô hình không bị overfitting hoặc underfitting.
- Kiểm tra khả năng tổng quát của mô hình trên dữ liệu mới.
- So sánh hiệu suất giữa các mô hình khác nhau để chọn lựa mô hình tốt nhất.
- Đảm bảo tính ổn định và bền vững.
- Đảm bảo chất lượng dự đoán trong ứng dụng thực tế.

CHƯƠNG 3: ỨNG DỤNG PHƯƠNG PHÁP VÀ XÂY DỰNG MÔ HÌNH

3.1 Mô tả bài toán

3.1.1 Giới thiệu bài toán và bộ dữ liệu

Mục tiêu của bài toán là dự đoán chất lượng nước mặt dựa trên các chỉ số hóa lý và sinh học quan trọng như nồng độ Ammonium Nitrogen (NH4+_N), nồng độ Nitrite Nitrogen (NO2-_N), nhiệt độ, nhu cầu oxy hóa sinh học (COD), nồng độ oxy hòa tan (DO), pH, vi khuẩn coliform và các chất dinh dưỡng khác. Các chỉ số này phản ánh tình trạng ô nhiễm và mức độ an toàn của nguồn nước, từ đó giúp đánh giá khả năng sử dụng nước cho các mục đích khác nhau như sinh hoạt, sản xuất. Kết quả dự đoán từ mô hình sẽ

cung cấp thông tin chính xác và kịp thời về chất lượng nước, giúp các nhà quản lý tài nguyên nước và môi trường đưa ra các quyết định chiến lược trong việc bảo vệ và cải thiện chất lượng nước. Điều này không chỉ giúp đảm bảo nguồn nước luôn an toàn cho sức khỏe cộng đồng, mà còn hỗ trợ việc lập kế hoạch bảo vệ và phát triển bền vững tài nguyên nước, giảm thiểu các tác động tiêu cực từ ô nhiễm và biến đổi khí hậu đối với môi trường

Thu thập bộ dữ liệu:

- Các thông số cần thu thập

  - NH4+_N: Nồng độ Ammonium Nitrogen
  - NO2-_N: Nồng độ Nitrite Nitrogen
  - Nhiệt độ: Nhiệt độ đo được
  - pH: Độ pH
  - COD: Nhu cầu oxy hóa học
  - DO: Hàm lượng oxy hòa tan
  - Coliform: Số lượng Coliform

Dữ liệu được thu thập từ tài liệu "Báo cáo quan trắc nước mặt tháng 1, tháng 2, tháng 3 năm 2024" do Trung tâm Quan trắc – Kỹ thuật Tài nguyên và Môi trường tỉnh Bình Dương cung cấp, bao gồm 442 mẫu được lấy từ 32 địa điểm đo khác nhau, trải dài trên khu vực tỉnh Bình Dương. Mỗi mẫu nước mặt được thu thập từ các vị trí và thời điểm khác nhau, phản ánh đa dạng các yếu tố tác động đến chất lượng nguồn nước trong khu vực nghiên cứu.

Phương pháp thu thập dữ liệu trong nghiên cứu này là phương pháp thống kê, trong đó, các số liệu đã được ghi nhận và tổng hợp từ báo cáo quan trắc sẽ được phân tích một cách có hệ thống. Việc phân tích này giúp đánh giá chính xác các chỉ tiêu chất lượng nước như pH, độ đục, hàm lượng các chất ô nhiễm, từ đó rút ra được những kết luận quan trọng về tình trạng môi trường nước trong suốt 13 tháng quan trắc. Thông qua

phương pháp này, chúng ta có thể làm rõ sự biến động chất lượng nước mặt tại các địa điểm khác nhau, qua đó cung cấp cơ sở khoa học để đưa ra các biện pháp quản lý và bảo vệ nguồn tài nguyên nước trong khu vực.

3.1.2 Quy trình thực nghiệm

Thuật toán xử lý: Mô hình xử lý tuần tự và song song qua các bước sau.

Procedure Hybrid_Model

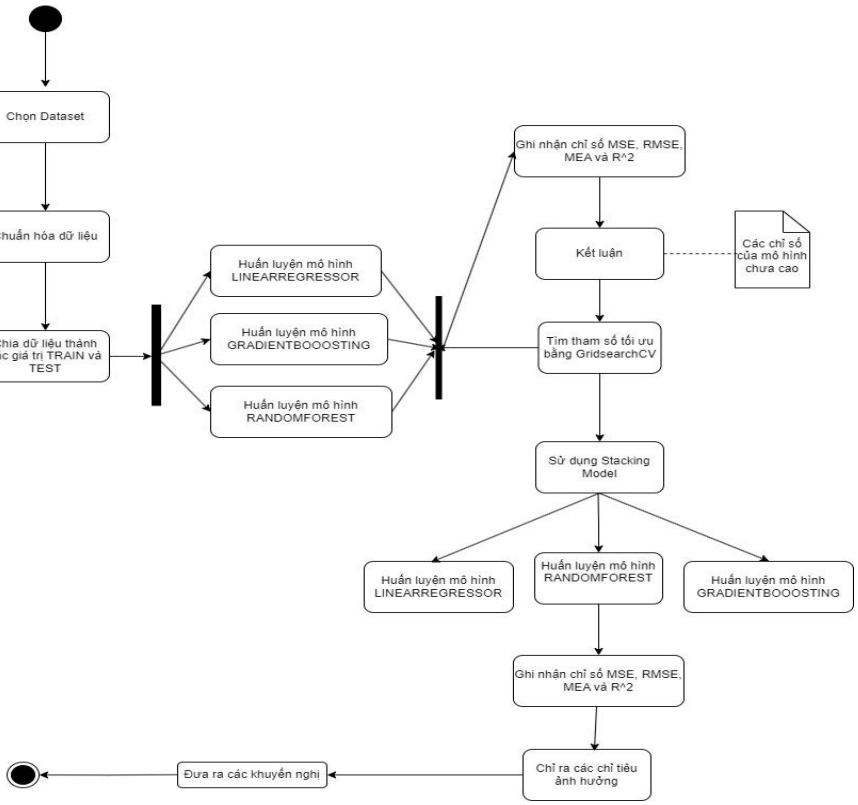
begin

- Bước 1: Chọn bộ dữ liệu.
- Bước 2: Chuẩn hóa dữ liệu (đưa về cùng một tiêu chuẩn).
- Bước 3: Chia dữ liệu thành 2 phần: dữ liệu để huấn luyện và dữ liệu để kiểm tra.
- Bước 4: Tìm các thông số tốt nhất cho mô hình bằng cách thử nhiều lần bằng GridSearchCV. GridSearchCV sẽ dừng lại khi đã thử nghiệm hết tất cả các kết hợp tham số trong lưới đã cung cấp.
- Bước 5: Tuần tự huấn luyện 3 mô hình Linear Regression, Gradient Boosting và RandomForest.
- Bước 6: Đánh giá các mô hình.
- Bước 7: Ghi nhận các chỉ số đánh giá (như MSE, MAE, R2) của từng mô hình.
- Bước 8: Nếu các chỉ số không đạt yêu cầu thì tiếp tục tối ưu hóa:
    - Bước 8.1: Sử dụng Stacking Model cho 3 mô hình Linear Regression, Gradient Boosting và RandomForest.
    - Bước 8.2: Đánh giá Stacking Model.
    - Bước 8.3: Ghi nhận các chỉ số đánh giá của Stacking Model
    - Bước 8.4: Tìm các yếu tố ảnh hưởng chính.
    - Bước 8.5: Đưa ra các khuyến nghị dựa trên các yếu tố ảnh hưởng.
    - Bước 8.6: Chỉ ra các yếu tố quan trọng nhất.

Ngược lại //Nếu các mô hình ban đầu đã đạt yêu cầu - Đưa ra khuyến nghị dựa trên kết quả.

end

Mô hình xử lý:



Hình 3.4 Mô hình xử lý đề xuất

Lựa chọn ba mô hình Hồi quy tuyến tính, Random Forest, và Gradient Boosting giúp đảm bảo tính đa dạng trong phương pháp và hiệu quả trong việc giải quyết các bài toán dự đoán. Hồi quy tuyến tính là mô hình đơn giản và dễ hiểu, phù hợp khi dữ liệu có mối quan hệ tuyến tính rõ ràng. Nó giúp cung cấp cái nhìn cơ bản về mối quan hệ giữa các biến và có thể triển khai nhanh chóng. Random Forest, với khả năng xử lý dữ liệu phức tạp và giảm thiểu overfitting, là một mô hình mạnh mẽ và có thể tổng quát tốt trên các tập dữ liệu lớn và đa dạng, nhờ vào việc sử dụng nhiều cây quyết định kết hợp. Cuối cùng, Gradient Boosting mang lại hiệu suất vượt trội, đặc biệt trong các bài toán phức tạp, khi các cây quyết định được xây dựng tuần tự để sửa chữa sai số của các cây trước đó. Mô hình này rất linh hoạt và có thể tối ưu hóa thông qua các tham số, giúp đạt được kết quả chính xác hơn so với các mô hình khác. Việc sử dụng ba mô hình này không chỉ giúp đánh giá hiệu suất của từng mô hình mà còn cung cấp sự linh

hoạt trong việc xử lý các dạng dữ liệu khác nhau, từ tuyến tính đến phi tuyến, và đảm bảo lựa chọn được mô hình tốt nhất cho bài toán cụ thể.

Ngoài 3 mô hình học máy sử dụng trên, em có tìm hiểu thêm kỹ thuật học kết hợp: stacking và áp dụng để nâng cao hiệu suất mô hình.

3.2 Các công cụ, thư viện dùng xây dựng

3.2.1 Các khung phần mềm học máy

Bản chất của bài toán Học máy là sử dụng dữ liệu để xây dựng mô hình có khả năng tự học và cải thiện từ kinh nghiệm. Điều này mở ra nhiều cơ hội mới trong việc giải quyết các vấn đề phức tạp và tạo ra giá trị từ dữ liệu. Các bước cơ bản làm một bài toán deep learning:

- Xây dựng bài toán.
- Chuẩn bị dữ liệu (dataset).
- Xử lý dữ liệu.
- Chọn và xây dựng mô hình.
- Đánh giá mô hình.
- Điều chỉnh tham số.
- Đưa ra dự đoán.

Các framework về deep learning ra đời với các đặc điểm giúp hỗ trợ người dùng:

- Tích hợp sẵn các thuật toán: Người dùng có thể dễ dàng truy cập và sử dụng nhiều thuật toán học máy thông dụng mà không cần phải cài đặt từng thuật toán riêng.
- Quy trình tiền xử lý dữ liệu đơn giản: Các framework cung cấp các công cụ tích hợp để xử lý dữ liệu, như xử lý giá trị thiếu, chuẩn hóa, và mã hóa, giúp người dùng tiết kiệm thời gian và công sức.
- Giao diện trực quan và thân thiện: Nhiều framework có giao diện đồ họa hoặc API dễ sử dụng, giúp người dùng không chuyên về lập trình cũng có thể dễ dàng thực hiện các tác vụ học máy.

- Tích hợp khả năng tự động hóa (AutoML)**:** Một số framework hỗ trợ tự động hóa quy trình chọn mô hình và tối ưu hóa tham số, giúp người dùng nhanh chóng tìm ra mô hình tốt nhất mà không cần phải thử nghiệm thủ công.
- Hỗ trợ đánh giá mô hình: Các công cụ đánh giá mô hình được tích hợp sẵn cho phép người dùng dễ dàng kiểm tra hiệu suất của mô hình với các chỉ số như độ chính xác, F1-score, và AUC, giúp đưa ra quyết định nhanh chóng.
- Khả năng mở rộng và phân tán**:** Một số framework được thiết kế để xử lý dữ liệu lớn và có thể chạy trên nhiều máy chủ, hỗ trợ người dùng trong việc xây dựng các ứng dụng học máy quy mô lớn.
- Tương thích với các ngôn ngữ lập trình khác**:** Nhiều framework hỗ trợ nhiều ngôn ngữ lập trình như Python, R, và Java, giúp người dùng linh hoạt hơn trong việc lựa chọn ngôn ngữ phù hợp.

Hàng loạt các thư viện hỗ trợ deep learning ra đời cùng với sự phát triển mạnh mẽ của phần cứng trong việc thiết kế GPU, các mô hình mạng nơ-ron ngày càng được xây dựng lớn hơn và sâu hơn để có thể đảm bảo được yêu cầu về độ chính xác cho các bài toán nhất định. Vì thế, việc tính toán các tham số cho mạng ngày càng phức tạp và rất khó để có thể xử lý được việc huấn luyện một mô hình xây dựng thủ công. Do vậy, các khung phần mềm hỗ trợ lập trình các mạng học sâu ra đời, giúp ta trừu tượng hóa các bước xử lý toán ẩn bên dưới và cung cấp các giao diện lập trình đơn giản, dễ sử dụng trong quá trình đào tạo. Trong đề tài này, khung phần mềm em sử dụng là Scikit-learn cho dự án của mình.

Scikit-learn là một thư viện mã nguồn mở cho Python, được thiết kế để hỗ trợ các tác vụ học máy và phân tích dữ liệu. scikit-learn cung cấp nhiều công cụ và thuật toán mạnh mẽ cho các bài toán như phân loại, hồi quy, phân cụm và giảm chiều dữ liệu. Thư viện này nổi bật nhờ vào tính đơn giản và dễ sử dụng, giúp người dùng dễ dàng xây dựng và triển khai các mô hình học máy.

Scikit-learn được coi là một thư viện ‘high-level’ cho học máy, cho phép người dùng thực hiện các tác vụ phức tạp mà không cần phải hiểu chi tiết về từng thuật toán. Thư viện này ưu tiên trải nghiệm của người lập trình và tính hiệu quả trong việc phát triển mô hình, với các đặc điểm nổi bật như:

- Thư viện phong phú: Scikit-learn cung cấp một bộ sưu tập lớn các thuật toán học máy, từ hồi quy tuyến tính đến cây quyết định và Random Forest, giúp người dùng dễ dàng áp dụng cho nhiều bài toán khác nhau.
- Tiền xử lý dữ liệu tích hợp: Thư viện hỗ trợ nhiều công cụ để tiền xử lý dữ liệu, như chuẩn hóa, mã hóa và xử lý giá trị thiếu, giúp đơn giản hóa quy trình trước khi xây dựng mô hình.
- Trải nghiệm người dùng tốt: scikit-learn có API nhất quán và dễ sử dụng, giúp người dùng dễ dàng học và áp dụng, ngay cả với những người mới bắt đầu.
- Tích hợp tốt với các thư viện khác: scikit-learn hoạt động mượt mà với các thư viện phổ biến khác như NumPy và pandas, cho phép người dùng dễ dàng xử lý và phân tích dữ liệu.
- Hỗ trợ đánh giá mô hình: scikit-learn cung cấp nhiều công cụ đánh giá và lựa chọn mô hình, giúp người dùng nhanh chóng kiểm tra và tối ưu hóa hiệu suất của mô hình.

Với những đặc điểm trên, Scikit-learn đã trở thành một trong những thư viện học máy phổ biến nhất trong cộng đồng nghiên cứu và phát triển ứng dụng, giúp người dùng dễ dàng tiếp cận và thực hiện các dự án học máy một cách hiệu quả.

Scikit là một gói Python khác có thể thực hiện nhiều tác vụ học máy hữu ích:

- Hồi quy tuyến tính
- Hồi quy cây quyết định
- Hồi quy Random Forest
- SVM
- Mô hình giảm dần độ dốc ngẫu nhiên

Scikit cung cấp các công cụ phân tích mô hình như ma trận hỗn loạn để đánh giá mô hình hoạt động tốt như thế nào. Nhiều khi, bạn có thể bắt đầu công việc ML trong scikit-learn và sau đó chuyển sang một khung khác. Ví dụ: scikit-learn có các công cụ xử lý trước dữ liệu tuyệt vời cho dữ liệu phân loại mã hóa một lần.

3.2.2 Các thư viện sử dụng

3.2.2.1 Thư viện Numpy (Numeric Python)

Numpy (Numeric Python) là một dự án mã nguồn mở nhằm hỗ trợ tính toán số với Python và là một thư viện toán học phổ biến và mạnh mẽ của Python. Cho phép làm việc hiệu quả với ma trận và mảng, đặc biệt là dữ liệu ma trận và mảng lớn với tốc độ xử lý nhanh hơn nhiều lần khi chỉ sử dụng "core Python" đơn thuần.

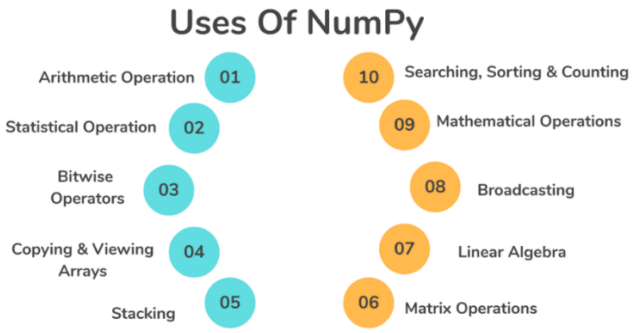
Năm 2005, Travis Oliphant đã tạo NumPy bằng cách đưa các tính năng của mô-đun Numeric vào một mô-đun khác Numarray. Đây là một mô-đun mở rộng của Python, phần lớn được viết bằng C, cung cấp các chức năng khác nhau có khả năng thực hiện các phép tính số với tốc độ cao. Ngoài ra thư viện Numpy còn cung cấp nhiều cấu trúc dữ liệu mạnh mẽ khác nhau, triển khai các mảng và ma trận đa chiều. Các cấu trúc dữ liệu này được sử dụng để tính toán tối ưu thuật toán liên quan đến mảng và ma trận.

Với cuộc cách mạng của khoa học dữ liệu, các thư viện phân tích dữ liệu như NumPy, SciPy, Pandas, … đã có sự phát triển vượt bậc với cú pháp dễ dàng hơn nhiều so với các ngôn ngữ lập trình khác, python là ngôn ngữ lựa chọn hàng đầu cho các nhà khoa học dữ liệu. Thư viện NumPy cung cấp một cách thuận tiện và hiệu quả để xử lý một lượng lớn dữ liệu và cũng rất tiện lợi với phép nhân ma trận và định hình lại dữ liệu, vì thế nó nhanh chóng nên hợp lý khi làm việc với một bộ dữ liệu lớn. Thư viện Numpy có những ưu điểm khi sử dụng để phân tích dữ liệu như sau:

- NumPy thực hiện toán học và logic mảng.
- NumPy thực hiện hiệu quả các mảng đa chiều.
- NumPy thực hiện các phép tính khoa học.
- NumPy có khả năng thực hiện Fourier Transform và định hình lại dữ liệu được lưu trữ trong các mảng đa chiều.
- NumPy cung cấp các hàm tích hợp cho đại số tuyến tính và tạo số ngẫu nhiên.

- Sự kết hợp của NumPy với SciPy và Matplotlib được sử dụng thay thế cho MATLAB vì Python là ngôn ngữ lập trình hoàn chỉnh hơn và dễ dàng hơn MATLAB.

  Các ứng dụng của thư viện NumPy được thể hiện ở Hình 3.2:



Hình 3.2 Các ứng dụng của thư viện Numpy

- Thực hiện các phép toán số học: NumPy hỗ trợ thực hiện các phép toán cơ bản như cộng, trừ, nhân, chia trên các mảng (arrays).
- Thống kê: Cung cấp các hàm thống kê như trung bình (mean), trung vị (median), phương sai (variance), v.v.
- Toán tử bit: Thực hiện các phép toán bitwise như AND, OR, XOR trên dữ liệu.
- Sao chép và xem các mảng: NumPy hỗ trợ sao chép và tạo các mảng con (views) mà không làm thay đổi mảng gốc.
- Xếp chồng mảng: Hỗ trợ ghép hoặc xếp chồng các mảng theo chiều ngang hoặc chiều dọc.
- Phép toán ma trận: Bao gồm nhân ma trận, chuyển vị (transpose), tính định thức, và nghịch đảo ma trận.
- Đại số tuyến tính: NumPy hỗ trợ các phép toán đại số tuyến tính phức tạp như giải hệ phương trình tuyến tính.
- Broadcasting: Cho phép thực hiện các phép toán trên mảng có kích thước không khớp mà không cần mở rộng dữ liệu.
- Các phép toán toán học: Bao gồm lượng giác (sin, cos), hàm mũ (exp), logarit (log).
- Tìm kiếm, sắp xếp và đếm: NumPy hỗ trợ các thao tác như tìm kiếm giá trị, sắp xếp các phần tử, và đếm số lượng giá trị.

3.2.2.2 Thư viện Matplotlib

Matplotlib là một thư viện vẽ đồ thị rất mạnh mẽ hữu ích cho những người làm việc với Python và NumPy. Module được sử dụng nhiều nhất của Matplotib là Pyplot cung cấp giao diện như MATLAB nhưng thay vào đó, nó sử dụng Python và nó là nguồn mở. Các kiểu biểu đồ của Matplotlib có thể được tìm thấy như

- Mục tiêu đơn giản hóa tối đa công việc vẽ biểu đồ qua câu lệnh được cung cấp sẵn.
- Matplotlib hỗ trợ rất nhiều loại biểu đồ, đặc biệt là các loại được sử dụng trong nghiên cứu hoặc kinh tế như biểu đồ dòng, đường, tần suất (histograms), phổ, tương quan, errorcharts, scatterplots, …
- Cấu trúc matplotlib gồm nhiều phần được phục vụ cho các mục đích sử dụng khác nhau.

Trong đề tài này, thư viện Matplotlib được sử chủ yếu để biểu diễn kết quả đánh giá mô hình dưới dạng biểu đồ trực quan, dựa vào đó, ta sẽ thực hiện được các bước điều chỉnh các tham số cũng như cấu trúc của mô hình sao cho nó đạt được hiệu năng tối ưu nhất.

3.2.2.3 Thư viện Pandas

Thư viện pandas trong python là một thư viện mã nguồn mở, hỗ trợ đắc lực trong thao tác dữ liệu. Đây cũng là bộ công cụ phân tích và xử lý dữ liệu mạnh mẽ của ngôn ngữ lập trình python. Thư viện này được sử dụng rộng rãi trong cả nghiên cứu lẫn phát triển các ứng dụng về khoa học dữ liệu. Thư viện này sử dụng một cấu trúc dữ liệu riêng là Dataframe. Pandas cung cấp rất nhiều chức năng xử lý và làm việc trên cấu trúc dữ liệu này. Chính sự linh hoạt và hiệu quả đã khiến cho pandas được sử dụng rộng rãi.

- DataFrame đem lại sự linh hoạt và hiệu quả trong thao tác dữ liệu và lập chỉ mục.
- Là một công cụ cho phép đọc/ ghi dữ liệu giữa bộ nhớ và nhiều định dạng file: csv, text, excel, sql database, hdf5.
- Liên kết dữ liệu thông minh, xử lý được trường hợp dữ liệu bị thiếu. Tự động đưa dữ liệu lộn xộn về dạng có cấu trúc.
- Dễ dàng thay đổi bố cục của dữ liệu.
- Tích hợp cơ chế trượt, lập chỉ mục, lấy ra tập con từ tập dữ liệu lớn.
- Có thể thêm, xóa các cột dữ liệu.

- Tập hợp hoặc thay đổi dữ liệu với group by cho phép bạn thực hiện các toán tử trên tập dữ liệu.
- Hiệu quả cao trong trộn và kết hợp các tập dữ liệu.
- Lập chỉ mục theo các chiều của dữ liệu giúp thao tác giữa dữ liệu cao chiều và dữ liệu thấp chiều.
- Tối ưu về hiệu năng.

Pandas được sử dụng rộng rãi trong cả học thuật và thương mại. Bao gồm thống kê, thương mại, phân tích, quảng cáo, …

3.2.3 Các công nghệ hỗ trợ

3.2.3.1 Visual Studio Code

Visual Studio Code (VS Code) là một trình soạn thảo mã nguồn miễn phí, đa nền tảng, được phát triển bởi Microsoft. Nó đã nhanh chóng trở thành một trong những trình soạn thảo phổ biến nhất dành cho các nhà phát triển, nhờ giao diện thân thiện, tính năng mạnh mẽ và khả năng mở rộng cao

Tính năng nổi bật:

- Hỗ trợ đa ngôn ngữ: VSCode hỗ trợ nhiều ngôn ngữ lập trình như JavaScript, Python, Java, C++, C#, PHP, và nhiều ngôn ngữ khác thông qua các tiện ích mở rộng
- Tính năng IntelliSense: Cung cấp gợi ý mã thông minh, hoàn thành mã tự động và thông tin về kiểu dữ liệu, giúp lập trình viên viết mã nhanh chóng và chính xác hơn
- Giao diện người dùng thân thiện: Giao diện trực quan và dễ tùy chỉnh, giúp người dùng dễ dàng điều hướng và sử dụng nhiều chức năng khác nhau
- Tích hợp Git: Hỗ trợ quản lý phiên bản với Git ngay trong giao diện, cho phép người dùng thực hiện các thao tác như commit, push, pull và xem lịch sử thay đổi
- Terminal tích hợp: Cung cấp terminal tích hợp, cho phép người dùng chạy lệnh trực tiếp mà không cần rời khỏi trình soạn thảo
- Tiện ích mở rộng phong phú: Có một kho tiện ích mở rộng đa dạng, cho phép người dùng mở rộng và tùy chỉnh tính năng của VSCode theo nhu cầu riêng.
- Debugging mạnh mẽ: Tính năng gỡ lỗi tích hợp giúp lập trình viên dễ dàng kiểm tra và sửa lỗi trong mã nguồn.

- Hỗ trợ phát triển web: Cung cấp nhiều tính năng hỗ trợ phát triển web, bao gồm tích hợp với các framework như Angular, React và Vue.js.

3.2.3.2 Jupyter

Jupyter là một dự án mã nguồn mở cung cấp một môi trường tương tác cho việc viết và chạy mã, chủ yếu cho ngôn ngữ Python. Jupyter Notebooks cho phép người dùng tạo và chia sẻ tài liệu chứa mã, văn bản, hình ảnh và biểu đồ, mang lại trải nghiệm học tập và phát triển mạnh mẽ.

Tính năng nổi bật của Jupyter

- Tương tác trực tiếp: Cho phép thực hiện mã từng ô một và xem kết quả ngay lập tức, rất hữu ích trong việc thử nghiệm và phân tích dữ liệu.
- Hỗ trợ nhiều ngôn ngữ: Ngoài Python, Jupyter cũng hỗ trợ nhiều ngôn ngữ khác thông qua các kernel như R, Julia, và Scala.
- Tài liệu phong phú: Kết hợp mã và văn bản mô tả trong cùng một tài liệu, giúp dễ dàng trình bày kết quả và chia sẻ kiến thức.
- Tích hợp với thư viện khoa học dữ liệu: Hỗ trợ mạnh mẽ cho các thư viện như NumPy, Pandas, Matplotlib, và SciPy, rất lý tưởng cho phân tích dữ liệu và học máy.

3.2.3.3 Tích hợp VSCode với Jupyter

VSCode cung cấp một tiện ích mở rộng dành riêng cho Jupyter, cho phép người dùng mở và chỉnh sửa các file Jupyter Notebook (.ipynb) trực tiếp trong VSCode. Điều này mang lại nhiều lợi ích:

- Giao diện dễ sử dụng: VSCode kết hợp giao diện trực quan của mình với các chức năng của Jupyter, giúp người dùng dễ dàng thao tác.
- Tính năng gỡ lỗi: Có thể sử dụng tính năng gỡ lỗi mạnh mẽ của VSCode ngay trong các notebook.
- Thời gian thực hiện: Một lợi ích đơn giản nhưng tiện dụng là mỗi ô hiển thị thanh tiến trình di chuyển khi thực thi mã và cho thấy cần bao nhiêu giây để thực hiện. Nếu bạn có các quy trình mất vài giây hoặc chạy lâu hơn, tính năng nhỏ này rất hữu ích và có sẵn.

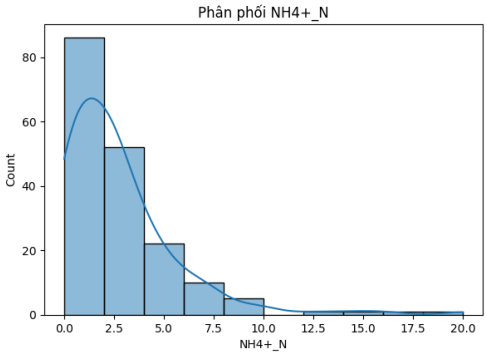
3.3 Các bước thực nghiệm

3.3.1 Phân tích và tiền xử lý dữ liệu

Sử dụng các biểu đồ và đồ thị để trực quan hóa dữ liệu và giúp hiểu rõ hơn về các thuộc tính trong bộ dữ liệu.

3.3.1.1 Trực quan hóa dữ liệu

Thuộc tính NH4+_N:



Hình 3.1 Biểu đồ phân phối NH4+_N

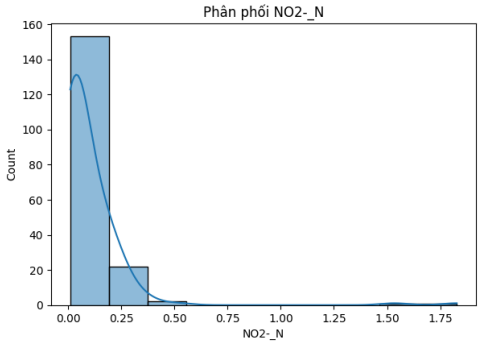
Trục hoành: Đại diện cho các giá trị của NH4+_N trong mẫu nước.

Trục tung: Đại diện cho số lượng mẫu (Count) trong từng khoảng giá trị của NH4+_N.

Nhận xét:

- Hầu hết các giá trị NH4+_N tập trung quanh khoảng từ 0 đến 2, cho thấy đây là phạm vi phổ biến của nồng độ Ammonium trong mẫu nước.
- Biểu đồ có hình dạng phân phối lệch phải (skewed right), nghĩa là phần lớn các giá trị NH4+_N có giá trị nhỏ, nhưng vẫn có một số mẫu có giá trị cao hơn.
- Dữ liệu có một đỉnh rõ ràng ở khoảng 1.0, cho thấy một sự tập trung mạnh mẽ ở mức nồng độ này, nhưng vẫn có một số ít mẫu có giá trị NH4+_N lớn hơn, lên đến khoảng 20.

Thuộc tính NO2-_N:



Hình 3 2 Biểu đồ phân phối NO2-_N

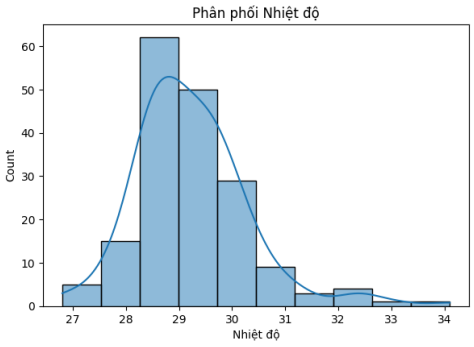
Trục hoành: Đại diện cho các giá trị của NO2-_N trong mẫu nước.

Trục tung: Đại diện cho số lượng mẫu trong từng khoảng giá trị của NO2-_N.

Nhận xét:

- Hầu hết các giá trị NO2-_N tập trung quanh 0, cho thấy nồng độ Nitrit Nitrogen trong mẫu nước chủ yếu thấp.
- Biểu đồ có hình dạng phân phối lệch phải, với phần lớn các giá trị NO2-_N nằm ở mức rất thấp. Một số ít mẫu có giá trị cao hơn, nhưng số lượng này rất hạn chế.
- Đỉnh của phân phối nằm ở gần 0, với một số ít giá trị cao hơn, cho thấy Nitrit Nitrogen chủ yếu không hiện diện trong mẫu nước, và chỉ có một vài mẫu nước có nồng độ Nitrit Nitrogen cao.

Thuộc tính Nhiệt độ:



Hình 3.3 Biểu đồ phân phối Nhiệt độ

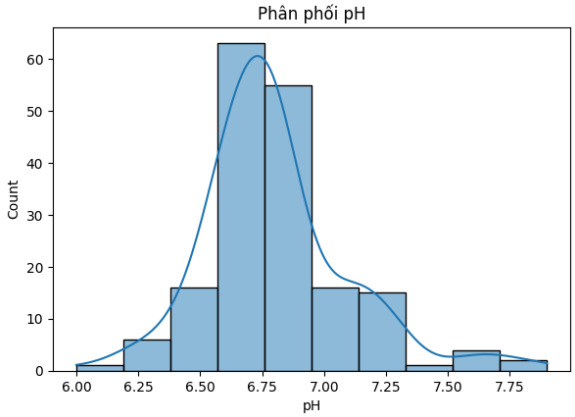
Trục hoành (x-axis): Giá trị Nhiệt độ (°C).

Trục tung (y-axis): Số lượng mẫu (Count) trong từng khoảng giá trị nhiệt độ.

Nhận xét:

- Hầu hết các giá trị Nhiệt độ tập trung quanh khoảng 28.0°C đến 28.5°C, cho thấy đây là nhiệt độ phổ biến trong các mẫu nước được thu thập.
- Sự phân phối có hình dạng gần như hình chuông, với một số giá trị cực trị ở hai bên, có thể chỉ ra sự biến động của nhiệt độ trong các điều kiện môi trường khác nhau.

Thuộc tính pH:



Hình 3.4 Biểu đồ phân phối pH

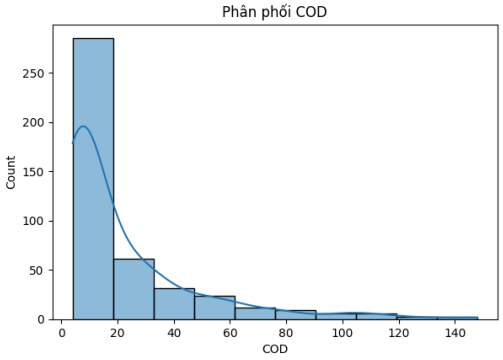
Trục hoành: Giá trị pH.

Trục tung: Số lượng mẫu trong từng khoảng giá trị pH.

Nhận xét:

- Hầu hết các giá trị pH nằm trong khoảng từ 6.5 đến 7.5, cho thấy nước trong khu vực này có độ pH tương đối ổn định và phù hợp với tiêu chuẩn môi trường
- Đường phân phối cho thấy rằng hầu hết các mẫu có pH khoảng 6.8, cho thấy môi trường nước có tính kiềm nhẹ.

Thuộc tính COD:



Hình 3.5 Biểu đồ phân phối COD

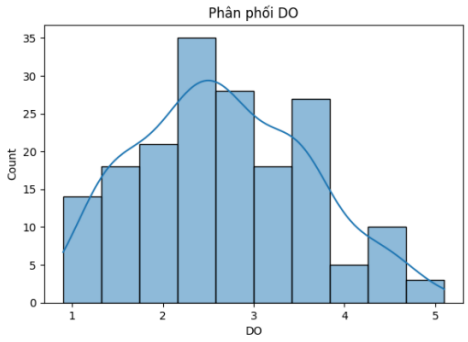
Trục hoành: Giá trị COD (mg/l).

Trục tung: Số lượng mẫu trong từng khoảng giá trị COD.

Nhận xét:

- Giá trị COD phân bố không đồng đều, tập trung chủ yếu ở khoảng 0 đến 20 mg/l, với số lượng mẫu giảm dần khi giá trị COD tăng.
- Đường phân phối cho thấy phần lớn các mẫu có giá trị COD thấp, phản ánh mức độ ô nhiễm hữu cơ nhẹ tại nhiều khu vực. Tuy nhiên, vẫn có một số ít mẫu với giá trị COD cao (> 60 mg/l), điều này có thể là dấu hiệu của các khu vực bị ô nhiễm nặng do nước thải chứa nhiều chất hữu cơ từ các nguồn công nghiệp, nông nghiệp hoặc sinh hoạt.
- Việc kiểm soát các nguồn thải này là cần thiết để đảm bảo chất lượng nước và giảm thiểu nguy cơ ô nhiễm môi trường.

Thuộc tính DO:



Hình 3.6 Biểu đồ phân phối DO

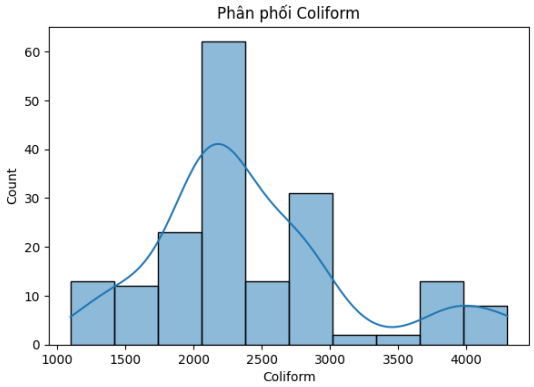
Trục hoành: Giá trị DO (mg/l).

Trục tung: Số lượng mẫu trong từng khoảng giá trị DO.

Nhận xét:

- Giá trị DO có sự biến động lớn, với các giá trị chủ yếu tập trung ở khoảng từ 2 đến 5 mg/l.
- Đường phân phối cho thấy rằng có nhiều mẫu với DO thấp, điều này có thể chỉ ra rằng một số khu vực trong nghiên cứu có thể bị ô nhiễm hoặc có ít oxy hòa tan hơn, ảnh hưởng đến sự sống của các sinh vật dưới nước.

Thuộc tính Coliform:



Hình 3.7 Biểu đồ phân phối Coliform

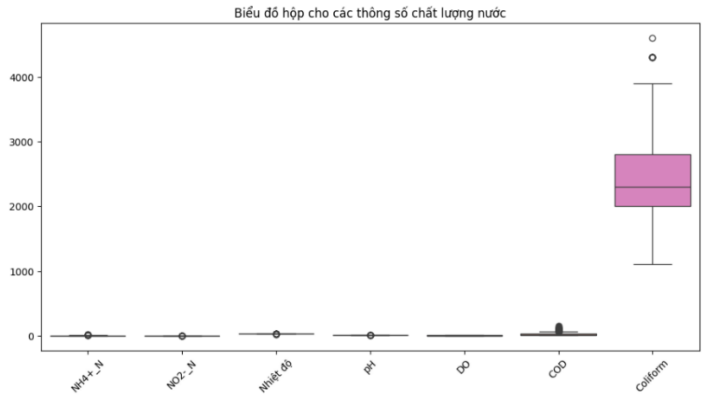
Trục hoành: Giá trị Coliform (MPN/100ml).

Trục tung: Số lượng mẫu trong từng khoảng giá trị Coliform.

Nhận xét:

- Số lượng Coliform trong mẫu có sự phân bố không đồng đều, với phần lớn mẫu có giá trị khoảng từ 1000 đến 2500 MPN/100ml.
- Điều này cho thấy có khả năng ô nhiễm vi sinh vật trong nước, vì Coliform là chỉ số quan trọng cho chất lượng nước và thường được sử dụng để kiểm tra mức độ ô nhiễm.

Các thông số chất lượng nước:



Hình 3.8 Biểu đồ hộp cho các thông số chất lượng nước

Trục hoành: Đại diện cho các thông số chất lượng nước: NH4+_N, NO2-_N, Nhiệt độ, pH, DO, COD và Coliform.

Trục tung: Đại diện cho giá trị của từng thông số.

Cấu trúc của biểu đồ hộp:

- Phần giữa của hộp: Đại diện cho khoảng giữa (interquartile range - IQR) của dữ liệu, nơi 50% dữ liệu nằm giữa Q1 (25th percentile) và Q3 (75th percentile).
- Đường giữa hộp: Thể hiện giá trị trung vị (median) của dữ liệu.
- Các đường kẻ (whiskers): Chỉ ra sự phân bố của dữ liệu nằm ngoài khoảng IQR, thường là từ Q1 - 1.5 * IQR đến Q3 + 1.5 * IQR.
- Các điểm ngoài (outliers): Các giá trị nằm ngoài đường kẻ whiskers, cho thấy những giá trị cực trị trong dữ liệu.
- NH4+_N và NO2-_N: Các chỉ số này có phân phối rất hẹp, với phần lớn các giá trị nằm gần mức 0. Không có giá trị ngoại lai rõ ràng, điều này có thể cho thấy nồng độ NH4+_N và NO2-_N trong mẫu nước ở mức thấp và ổn định.
- Nhiệt độ: Giá trị của Nhiệt độ nằm trong khoảng hẹp và không có giá trị ngoại lai rõ ràng. Điều này cho thấy Nhiệt độ trong các mẫu nước ổn định, không có sự biến động lớn.

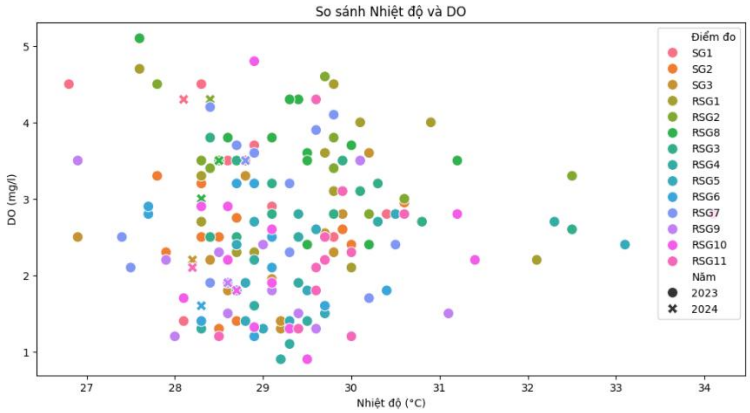
- pH: Phân phối pH cũng hẹp, với trung vị khoảng 6.5 đến 7.5. Không có giá trị ngoại lai đáng chú ý, cho thấy chất lượng nước khá ổn định về độ pH, không có sự thay đổi đáng kể trong môi trường nước.

- DO: Phân phối DO có thể cho thấy một số biến động, nhưng nhìn chung giá trị không có giá trị ngoại lai lớn. Điều này có thể chỉ ra rằng nước trong khu vực nghiên cứu vẫn đủ oxy hòa tan cho các sinh vật sống, tuy nhiên có thể có sự biến động nhẹ.

- COD: Phân phối COD có thể cho thấy sự biến động lớn hơn, với một số giá trị ngoại lai. Điều này có thể chỉ ra rằng một số khu vực có mức độ ô nhiễm hữu cơ cao, cần được kiểm tra và xử lý kịp thời để bảo vệ chất lượng nước.

- Coliform: Phân phối của Coliform cho thấy có sự biến động lớn với một số giá trị ngoại lai. Điều này có thể chỉ ra rằng một số khu vực có mức ô nhiễm vi sinh vật cao hơn. Đây là vấn đề cần được chú ý trong việc quản lý chất lượng nước, vì mức độ Coliform cao có thể ảnh hưởng đến sức khỏe cộng đồng.

So sánh thông số Nhiệt độ và DO:



Hình 3.9 Biểu đồ So sánh Nhiệt độ và DO

Trục hoành: Đại diện cho giá trị Nhiệt độ (°C).

Trục tung: Đại diện cho hàm lượng DO (mg/l).

Màu sắc của điểm: Thể hiện các Điểm đo khác nhau (SG1, SG2, RSG3, …), giúp phân biệt các khu vực lấy mẫu khác nhau.

Kích thước điểm: Có thể đại diện cho các năm (2023 và 2024), cho thấy sự phân bố của các mẫu nước qua các năm.

Nhận xét về mối quan hệ giữa Nhiệt độ và DO:

- Xu hướng tổng thể: Biểu đồ cho thấy rằng hàm lượng DO có sự biến động nhưng không có mối tương quan mạnh mẽ với Nhiệt độ. Một số mẫu có nhiệt độ cao nhưng hàm lượng DO lại thấp, điều này có thể chỉ ra rằng trong các điều kiện khác nhau (như ô nhiễm hoặc cấu trúc sinh thái), DO không hoàn toàn phụ thuộc vào nhiệt độ.
- Độ phân bố của các điểm: Có nhiều điểm nằm trong khoảng nhiệt độ từ 27.5 đến 29.5°C, cho thấy đây là phạm vi nhiệt độ phổ biến trong các mẫu nước.
- DO có giá trị biến động, với nhiều điểm nằm dưới 3 mg/l, điều này có thể là chỉ số cho thấy môi trường nước có thể không đủ oxy hòa tan, gây ảnh hưởng đến sự sống của sinh vật thủy sinh.

3.3.1.2 Xử lý dữ liệu

Tiền xử lý dữ liệu:

- Loại bỏ các giá trị thiếu (NaN)

- Dữ liệu thiếu trong các đặc trưng (X) được loại bỏ bằng phương pháp dropna().
- Đồng thời, chỉ số của các mẫu hợp lệ trong X được sử dụng để lọc lại các giá trị tương ứng trong y nhằm đảm bảo tính đồng nhất giữa X và y.

Bảng 3.1 Loại bỏ dữ liệu thiếu

```
wqi_data_cleaned = wqi_data.dropna()
```

- Chuyển đổi dữ liệu sang kiểu số:

Kiểu số (numeric) bao gồm số nguyên (integer) và số thực (float), giúp dữ liệu có thể tham gia vào các phép toán hoặc phân tích thống kê. Trong thực tế, khi làm việc với dữ liệu, không phải lúc nào các giá trị cũng có thể trực tiếp chuyển đổi sang kiểu số. Để giải quyết vấn đề này, khi sử dụng thư viện Pandas trong Python, các giá trị không thể chuyển đổi có thể được thay thế bằng NaN (Not a Number), một giá trị đại diện cho dữ liệu bị thiếu hoặc không hợp lệ. Điều này giúp đảm bảo tính nhất quán và tránh lỗi trong quá trình xử lý dữ liệu hoặc phân tích. NaN cũng cho phép bạn áp dụng kỹ thuật

xử lý dữ liệu khác như loại bỏ, thay thế, hoặc ước lượng giá trị bị thiếu mà không ảnh hưởng đến dữ liệu hợp lệ.

Bảng 3.2 Chuyển đổi dữ liệu sang kiểu số

```
numeric_columns = ['NH4+_N', 'NO2-_N', 'Nhiệt độ', 'pH', 'COD',
'DO', 'Coliform', 'WQI']
for col in numeric_columns:
    wqi_data_cleaned[col]=pd.to_numeric(wqi_data_cleaned[col],
errors='coerce')
```

3.3.2 Chuẩn bị dữ liệu

Chia tập dữ liệu: Chia dữ liệu thành tập huấn luyện 80% và tập kiểm tra 20%.

- Xác định các đặc trưng và biến mục tiêu
- Đặc trưng đầu vào (X): Gồm các cột: pH, DO, Coliform, NH4+_N, NO2-_N, và COD. Đây là các chỉ số được chọn làm cơ sở để dự đoán chất lượng nước.
- Biến mục tiêu (y): Chỉ số WQI đại diện cho chất lượng nước.
- Kích thước ban đầu của các tập dữ liệu:
  - X (Đặc trưng): (số lượng mẫu, số lượng đặc trưng) - thông tin được kiểm tra bằng X.shape.
  - y (Biến mục tiêu): (số lượng mẫu).
- Chia dữ liệu thành tập huấn luyện và kiểm tra
  - Tỷ lệ chia: 80% dữ liệu cho tập huấn luyện và 20% dữ liệu cho tập kiểm tra.
  - Cách thực hiện: Sử dụng hàm train_test_split từ thư viện sklearn.model_selection.
  - Tham số random_state=42: Được đặt để đảm bảo kết quả phân chia có thể tái lập.

Bảng 3.3 Chia tập dữ liệu

```
# Chia dữ liệu thành tập huấn luyện và kiểm tra
from sklearn.model_selection import train_test_split
# Tách lại X và y
X = final_data[['NH4+_N', 'NO2-_N', 'pH', 'DO', 'Coliform',
'COD']]  # Các đặc trưng
y = final_data['WQI'] # Chỉ số WQI
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42)
print("Số lượng mẫu trong X:", len(X))
print("Số lượng mẫu trong y:", len(y))
```

3.3.3 Huấn luyện mô hình và tối ưu tham số

3.3.3.1 Huấn luyện mô hình

Huấn luyện ba mô hình với bộ tham số chưa tối ưu

Bảng 3.4 Huấn luyện mô hình

```
from sklearn.ensemble import GradientBoostingRegressor,
RandomForestRegressor
from sklearn.linear_model import LinearRegression
# Mô hình Random Forest
rf_model = RandomForestRegressor(n_estimators=100,
random_state=42)
rf_model.fit(X_train, y_train)
# Dự đoán trên tập kiểm tra
rf_pred = rf_model.predict(X_test)
# Mô hình Hồi quy tuyến tính
lr_model = LinearRegression()
lr_model.fit(X_train, y_train)
# Dự đoán trên tập kiểm tra
lr_pred = lr_model.predict(X_test)
# Mô hình Gradient Boosting
gb_model = GradientBoostingRegressor(n_estimators=100,
learning_rate=0.1, max_depth=3, random_state=42)
gb_model.fit(X_train, y_train)
# Dự đoán trên tập kiểm tra
gb_pred = gb_model.predict(X_test)
```

Các thuật toán được sử dụng:

- Hồi quy tuyến tính (Linear Regression).

  - Được cài đặt qua LinearRegression từ thư viện sklearn.linear_model.

- Đây là một thuật toán học máy thuộc nhóm học giám sát, dùng để mô hình hóa mối quan hệ giữa một biến phụ thuộc (y) và một hoặc nhiều biến độc lập (X) bằng cách sử dụng một đường thẳng (tuyến tính).

- Hồi quy tuyến tính tìm cách tối ưu hóa các tham số (hệ số hồi quy) để dự đoán giá trị của y dựa trên giá trị của X. Đây là một thuật toán đơn giản và dễ hiểu nhưng có thể bị hạn chế khi dữ liệu có mối quan hệ phi tuyến.

- Random Forest (Random Forest).

- Được cài đặt qua RandomForestRegressor từ thư viện sklearn.ensemble.

- Đây là một thuật toán học máy thuộc nhóm học giám sát (supervised learning), sử dụng một tập hợp các cây quyết định (decision trees) để thực hiện dự đoán. Mỗi cây trong rừng đưa ra một dự đoán, và kết quả cuối cùng là trung bình (hoặc đa số) các dự đoán từ tất cả các cây.

- Thuật toán này có khả năng xử lý dữ liệu phức tạp và không yêu cầu tiền xử lý dữ liệu nhiều. Nó cũng có thể giảm thiểu hiện tượng overfitting nhờ vào việc sử dụng nhiều cây quyết định.

- Gradient Boosting:

- Được cài đặt qua GradientBoostingRegressor từ thư viện sklearn.ensemble.

- Đây là một thuật toán học máy thuộc nhóm học giám sát (supervised learning), sử dụng phương pháp tăng cường dần (boosting) để cải thiện độ chính xác dự đoán. Gradient Boosting xây dựng một tập hợp các mô hình cây quyết định (decision trees) nhỏ và kết hợp chúng lại bằng cách tối ưu hóa từng bước dựa trên lỗi của các cây trước đó.

- Thuật toán này hoạt động hiệu quả trên dữ liệu phức tạp, có khả năng xử lý tốt cả dữ liệu phi tuyến tính và không yêu cầu nhiều về tiền xử lý. Tuy nhiên, Gradient Boosting thường cần điều chỉnh các siêu tham số như learning rate và số lượng cây để đạt được hiệu suất tối ưu, đồng thời có thể nhạy cảm với hiện tượng overfitting nếu không được điều chỉnh cẩn thận.

3.3.3.2 Sử dụng GridSearchCV tối ưu tham số

Random Forest: Tối ưu hóa mô hình với bộ tham số như sau

Bảng 3.5 Tối ưu tham số Random Forest

```
# Định nghĩa phạm vi các tham số cho RandomForest
rf_param_grid = {
    'n_estimators': [100, 200, 300],
    'max_depth': [10, 20, 30],
    'min_samples_split': [5, 10, 15]
}
```

Trong đó:

- n_estimators: Số lượng cây quyết định trong rừng. Số cây quyết định sẽ quyết định độ mạnh mẽ của mô hình. Tăng số lượng cây giúp mô hình học được nhiều thông tin hơn và có khả năng dự đoán chính xác hơn. Tuy nhiên, việc tăng số lượng cây cũng làm tăng thời gian huấn luyện và tài nguyên tính toán.
- max_depth: kiểm soát độ sâu tối đa của mỗi cây quyết định. Độ sâu của cây quyết định là số mức phân tách (split) từ gốc đến các lá (leaf) của cây. Độ sâu của cây càng lớn thì cây sẽ càng phức tạp và có thể khớp tốt với dữ liệu huấn luyện (overfitting), nhưng lại có thể kém tổng quát khi gặp dữ liệu mới. Nếu độ sâu quá nhỏ, cây sẽ không đủ khả năng học được các đặc điểm phức tạp trong dữ liệu (underfitting).
- min_samples_split: xác định số lượng mẫu tối thiểu cần thiết để tiếp tục phân chia một nút trong cây quyết định. Nếu số mẫu tại một nút nhỏ hơn giá trị này, nút đó sẽ không bị phân chia thêm nữa. Ảnh hưởng đến độ sâu và cấu trúc của cây. Nếu giá trị này quá nhỏ, cây sẽ quá phức tạp và có thể dẫn đến overfitting. Nếu giá trị quá lớn, cây sẽ bị hạn chế trong việc học các đặc điểm phức tạp của dữ liệu.

Gradient Boosting: Tối ưu hóa mô hình với bộ tham số như sau

Bảng 3.6 Tối ưu tham số cho Gradient Boosting

```
# Định nghĩa phạm vi các tham số cho GradientBoosting
gb_param_grid = {
    'n_estimators': [50, 100, 200],
    'learning_rate': [0.01, 0.1, 0.2],
    'max_depth': [3, 5, 7]
}
```

Trong đó:

- n_estimators: Số lượng cây trong mô hình Gradient Boosting. Tăng số lượng cây giúp mô hình học được nhiều thông tin hơn và có thể cải thiện độ chính xác. Tuy nhiên, việc sử dụng quá nhiều cây có thể dẫn đến overfitting, tức là mô hình học quá chi tiết vào dữ liệu huấn luyện và không tổng quát tốt cho dữ liệu mới.
- learning_rate: điều chỉnh sự ảnh hưởng của mỗi cây vào mô hình cuối cùng. Tốc độ học thấp có nghĩa là mỗi cây đóng góp ít hơn vào việc sửa chữa các sai sót từ cây trước, giúp giảm nguy cơ overfitting, nhưng cũng làm cho quá trình huấn luyện trở nên chậm hơn. Tác dụng: Giảm learning_rate thường cần phải tăng số lượng cây (n_estimators) để mô hình học tốt hơn, vì mỗi cây sẽ học ít hơn, nhưng tổng thể mô hình có thể chính xác hơn. Ngược lại, tăng learning_rate có thể khiến mô hình học nhanh hơn nhưng dễ dẫn đến overfitting.
- max_depth: xác định độ sâu tối đa của mỗi cây quyết định. Ảnh hưởng đến khả năng mô hình học được các mối quan hệ phức tạp trong dữ liệu. Nếu max_depth quá lớn, cây sẽ quá phức tạp và có thể dẫn đến overfitting. Nếu giá trị này quá nhỏ, cây sẽ không đủ khả năng học được các đặc điểm quan trọng trong dữ liệu.

3.3.3.3 Stacking model với tham số tối ưu

Với hai mô hình Random Forest và Gradient Boosting đã được tối ưu tham số ở trên, em có sử dụng thêm kỹ thuật mô hình kết hợp Stacking với mô hình meta là Hồi quy tuyến tính. Kỹ thuật này không chỉ tận dụng được sức mạnh của các mô hình cơ sở mà còn mang lại sự linh hoạt và chính xác cao trong các bài toán thực tế.

Bảng 3.7 Stacking model với tham số tối ưu

```
from sklearn.ensemble import StackingRegressor
# Mô hình đã được tối ưu
optimized_models = {
    'RandomForest':
RandomForestRegressor(**best_rf_params),
    'LinearRegression': LinearRegression(),
    'GradientBoosting':
GradientBoostingRegressor(**best_gb_params)
}
# Mô hình meta
meta_model = LinearRegression()
# Tạo mô hình StackingRegressor với các mô hình cơ sở và
mô hình meta
stacking_model = StackingRegressor(
    estimators=[('rf', optimized_models['RandomForest']),
                ('lr',
optimized_models['LinearRegression']),
                ('gb',
optimized_models['GradientBoosting'])],
    final_estimator=meta_model
```

Trong tương lai, với các cải tiến về dữ liệu và meta model, mô hình kết hợp này có thể đạt được hiệu suất tốt hơn nữa, đáp ứng tốt yêu cầu của các ứng dụng dự đoán chất lượng nước trong thực tiễn.

3.4 Triển khai thực nghiệm

3.4.1 Kết quả huấn luyện mô hình

3.4.1.1 Đánh giá mô hình chưa tối ưu

Bảng 3.8 Kết quả huấn luyện mô hình

Thông số đánh giá mô hình	Linear Regression	Random Forest	GradientBoosting
MSE	4.2608	0.2027	0.1110
RMSE	2.0642	0.4502	0.3331
MAE	1.3812	0.2980	0.1840
R^2	0.5905	0.9805	0.9893

Qua kết quả ở trên ta có thêm nhận xét như sau:

Với mô hình Random Forest:

- Sai số MAE: 0.298, chỉ số này tương đối thấp cho thấy độ sai lệch tuyệt đối trung bình giữa giá trị dự đoán và giá trị thực tế là nhỏ. Điều này chứng tỏ mô hình Random Forest dự đoán khá chính xác.
- Sai số MSE: 0.2027, chỉ số này có giá trị tương đối thấp, điều này đồng thời cho thấy sự ổn định và độ chính xác của mô hình trong việc dự đoán.
- Sai số RMSE: 0.4502, chỉ số này nhỏ cho thấy mô hình Random Forest có độ chính xác cao và ít bị ảnh hưởng bởi các sai lệch lớn.
- Sai số R^2: 0.9805, Chỉ số này khá cao có nghĩa là mô hình giải thích được 98% sự biến động của biến mục tiêu. Đây là một chỉ số rất tốt, cho thấy mô hình đã khớp tốt với dữ liệu và có khả năng dự đoán chính xác.

Với mô hình Hồi quy tuyến tính:

- Sai số MAE: 1.38, chỉ số này tương đối cao, điều này cho thấy mô hình này có sự sai lệch lớn giữa giá trị dự đoán và giá trị thực tế. Điều này phản ánh Hồi quy tuyến tính có độ chính xác kém.
- Sai số MSE: 4.26, chỉ số tương đối cao cho thấy mô hình Hồi quy tuyến tính không phù hợp với dữ liệu. Sự sai lệch bình quân giữa giá trị thực và giá trị dự đoán là rất lớn.
- Sai số RMSE: 2.06, chỉ số này khá cao, điều này cho thấy các sai lệch giữa giá trị thực tế và giá trị dự đoán của mô hình khá lớn. Hệ số sai lệch lớn này có thể làm giảm độ tin cậy của mô hình trong việc dự đoán.
- Sai số R^2: 0.59, chỉ số khá thấp thể hiện mô hình chỉ giải thích được 59% sự biến động của dữ liệu. Điều này cho thấy Hồi quy tuyến tính có khả năng dự báo hạn chế và kém hiệu quả.

Với mô hình Gradient Boosting:

- Sai số MAE: 0.1839, với giá trị này cho thấy các dự đoán của mô hình rất gần với thực tế, không có sự sai lệch lớn.
- Sai số MSE: 0.1109, có giá trị khá thấp chứng tỏ mô hình có khả năng dự đoán chính xác.

- Sai số RMSE: 0.3331, có giá trị khá nhỏ, chứng tỏ mô hình thể hiện độ chính xác cao.
- Sai số R^2: 0.9893, giá trị gần bằng 1 chứng tỏ Gradient Boosting đã giải thích rất tốt sự biến thiên trong dữ liệu, cho thấy mô hình này phù hợp rất tốt với tập dữ liệu.

3.4.1.2 Mô hình sau khi tối ưu

Tối ưu mô hình hai mô hình Random Forest và GradientBoosting sử dụng GridSearchCV với bộ tham số đề cập ở trên, em thu được kết quả như sau

- Bộ tham số tốt nhất của mô hình Random Forest: {'max_depth': 20, 'min_samples_split': 5, 'n_estimators': 200}
- Bộ tham số tốt nhất của mô hình GradientBoosting: {'learning_rate': 0.2, 'max_depth': 3, 'n_estimators': 200}

Sau khi tối ưu hai mô hình trên với bộ tham số tốt nhất, em thực hiện kỹ thuật Stacking với 3 mô hình cơ sở là: hồi quy tuyến tính, Random Forest, Gradient, mô hình meta là hồi quy tuyến tính, kết quả độ chính xác của các mô hình đơn và stacking như bảng dưới đây:

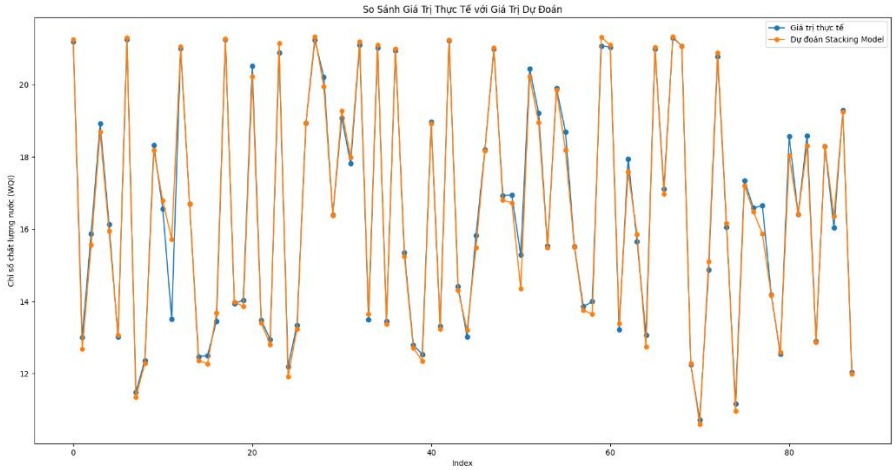
Bảng 3.9 Thống kê kết quả đánh giá các mô hình học máy dự báo chỉ số chất lượng nước

Thông số đánh giá	Các mô hình đơn			Mô hình kết hợp
	Hồi quy tuyến tính	Random Forest	GradientBoosting	Stack Model
MSE	4.2608	0.2027	0.1110	0.1046
RMSE	2.0642	0.4502	0.3331	0.323
MAE	1.3812	0.2980	0.1840	0.1815
R^2	0.5905	0.9805	0.9893	0.9899

Dựa trên các chỉ số đánh giá, mô hình kết hợp (Stack Model) cho thấy hiệu quả vượt trội so với các mô hình đơn như Hồi quy tuyến tính, Random Forest và Gradient Boosting. Cụ thể, mô hình Stack Model đạt các chỉ số MSE, RMSE và MAE thấp nhất, chứng tỏ sai lệch giữa giá trị dự đoán và thực tế là nhỏ nhất, đồng thời giảm được sai số

đáng kể so với các mô hình còn lại. Đặc biệt, Stack Model có R^2 cao nhất (0.9899), giải thích được gần 99% sự biến động của dữ liệu, cho thấy khả năng dự đoán chính xác và khớp tốt với dữ liệu. Ngược lại, Hồi quy tuyến tính có các chỉ số đánh giá kém nhất, với MSE và RMSE cao nhất, chỉ giải thích được 59% sự biến động của dữ liệu. Do đó, mô hình kết hợp thể hiện sự cải thiện rõ rệt về độ chính xác và khả năng dự đoán so với các mô hình đơn.

3.4.1.3 So *sánh Giá trị thực tế và Giá trị Dự đoán*



Hình 3.10 So sánh Giá trị thực tế và Giá trị Dự đoán

Trục hoành: Đại diện cho chỉ số mẫu (Index), thể hiện thứ tự của các điểm trong tập kiểm tra.

Trục tung: Đại diện cho chỉ số chất lượng nước (WQI).

Các điểm dữ liệu:

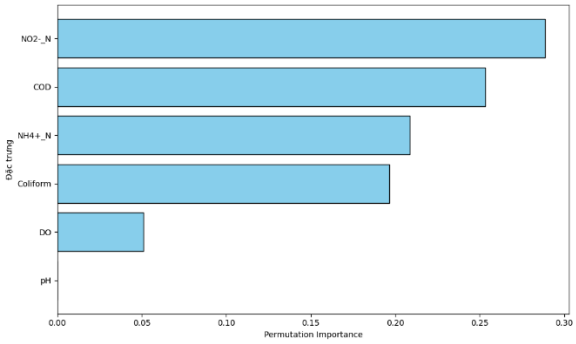
- Giá trị thực tế (thể hiện bằng hình tròn): Đại diện cho các giá trị thực tế của WQI.
- Dự đoán từ mô hình Stacking Model (đường màu cam, hình tròn): Đại diện cho các giá trị WQI dự đoán bởi mô hình Stacking.

Nhận xét:

- Giá trị dự đoán có xu hướng dao động mạnh hơn so với giá trị thực tế. Điều này có thể cho thấy mô hình đang gặp vấn đề với việc dự đoán các mẫu có tính chất phức tạp hoặc ngoại lệ.

- Mô hình Stacking có khả năng kết hợp nhiều mô hình con để tận dụng các ưu điểm riêng của chúng. Điều này giúp mô hình phản ánh tốt các xu hướng phi tuyến tính trong dữ liệu, và nhìn chung, các giá trị dự đoán khá sát với thực tế.
- Sai số vẫn xuất hiện ở những vùng có biến động lớn, có thể do dữ liệu huấn luyện chưa đủ phong phú hoặc mô hình chưa được tối ưu hóa hoàn toàn.
- Mô hình Stacking đã làm tốt trong việc phản ánh xu hướng tổng thể và phần lớn các giá trị thực tế của WQI. Tuy nhiên, để cải thiện khả năng dự đoán ở những vùng dữ liệu phức tạp, cần tập trung vào việc tăng cường dữ liệu và tối ưu hóa mô hình. Khi được cải thiện, mô hình này có tiềm năng mang lại độ chính xác cao hơn và phù hợp với các ứng dụng thực tế.

3.4.1.4 Ảnh hưởng của mô hình Stacking

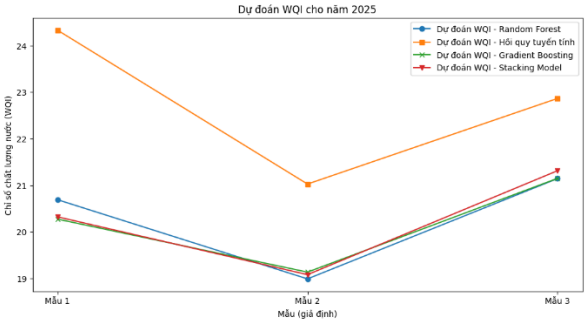


Hình 3.11 Sơ đồ chất ảnh hưởng của mô hình Stacking

Biểu đồ cho thấy các chất gây ô nhiễm chính ảnh hưởng đến chất lượng nước gồm NO2-N, NH4+-N, COD, Coliform, DO và pH. Trong đó, NO2-_N (Nitrit) và NH4+_N (Amoni) là những yếu tố quan trọng nhất, chủ yếu từ phân bón nông nghiệp, nước thải chăn nuôi và sinh hoạt, phản ánh mức độ ô nhiễm hóa học nghiêm trọng. COD biểu thị ô nhiễm hữu cơ và hóa chất khó phân hủy từ nước thải công nghiệp và sinh hoạt. Coliform cho thấy ô nhiễm vi sinh từ nước thải chưa xử lý. DO và pH, tuy ảnh hưởng thấp hơn, vẫn đóng vai trò trong hỗ trợ sinh vật thủy sinh và cân bằng hóa học nước.

Mô hình dự đoán chất lượng nước kết hợp Linear Regression, RandomForestRegressor và GradientBoostingRegressor với Permutation Feature Importance đánh giá tầm quan trọng các chỉ tiêu. Kết quả xác định NO2-_N, NH4+_N, COD và Coliform là các yếu tố ưu tiên giảm tải thông qua quản lý phân bón, xử lý nước thải công nghiệp và sinh hoạt.

3.4.2 Dự đoán cho tương lai



Hình 3.12 Dự đoán WQI năm 2025

Trục hoành (X): Đại diện cho chỉ số mẫu, thể hiện thứ tự của các điểm trong tập kiểm tra.

Trục tung (Y): Đại diện cho chỉ số chất lượng nước (WQI).

Các điểm dữ liệu:

- Dự đoán từ mô hình Random Forest (hình tròn): Các điểm thể hiện giá trị WQI dự đoán bởi mô hình Random Forest.
- Dự đoán từ mô hình Hồi quy tuyến tính (hình vuông): Các điểm thể hiện giá trị WQI dự đoán bởi mô hình Hồi quy tuyến tính.
- Dự đoán từ mô hình Gradient Boosting (hình thập tự): Các điểm thể hiện giá trị WQI dự đoán bởi mô hình Gradient Boosting.
- Dự đoán từ mô hình kết hợp Stacking Model (hình tam giác): Các điểm thể hiện giá trị WQI dự đoán bởi mô hình kết hợp Stacking Model.

Sự tương đồng: Cả bốn mô hình (Random Forest, Hồi quy tuyến tính, Gradient Boosting và Stacking Model) đều dự đoán WQI cho các mẫu trong năm 2025 với các giá trị gần nhau (ngoại trừ hồi quy tuyến tính). Điều này cho thấy các mô hình đang phản ánh một xu hướng chung trong dữ liệu chất lượng nước.

Xu hướng: Hầu hết các mô hình đều cho thấy xu hướng giảm nhẹ từ Mẫu 1 đến Mẫu 2 và tăng trở lại ở Mẫu 3. Điều này có thể cho thấy biến động chất lượng nước tại các mẫu, có khả năng phản ánh sự thay đổi trong điều kiện môi trường hoặc nguồn thải.

Độ chính xác: Mô hình Gradient Boosting và Stacking Model có xu hướng đưa ra các dự đoán ổn định và gần nhau hơn so với Hồi quy tuyến tính, vốn có độ chênh lệch lớn giữa các mẫu. Random Forest cũng cho ra kết quả ổn định, cho thấy phù hợp với dữ liệu phi tuyến. Hồi quy tuyến tính tỏ ra kém hiệu quả hơn khi xử lý dữ liệu có yếu tố phức tạp hoặc phi tuyến.

Giá trị cụ thể: Nếu so sánh các giá trị cụ thể trong biểu đồ, Gradient Boosting, Random Forest và Stacking Model cho ra các giá trị tương đồng, nằm trong khoảng 19-21 cho cả ba mẫu. Hồi quy tuyến tính lại chênh lệch lớn hơn, đặc biệt ở Mẫu 1 và Mẫu 3 (vượt ngưỡng 24). Điều này nhấn mạnh sự cần thiết phải áp dụng các mô hình phi tuyến để có dự đoán chính xác hơn.

3.4.3 Đánh giá khả năng áp dụng thực tế của mô hình

Random Forest có khả năng áp dụng thực tế cao, đặc biệt với dữ liệu phi tuyến và biến động lớn. Với các chỉ số hiệu suất ấn tượng (MAE: 0.29, MSE: 0.20, RMSE: 0.45, R^2: 0.98), mô hình dự đoán chính xác chất lượng nước và xử lý tốt các mối quan hệ phức tạp giữa các biến. Đây là công cụ mạnh mẽ, phù hợp trong lĩnh vực môi trường với dữ liệu đa dạng và không tuyến tính. Hồi quy tuyến tính: Mặc dù mô hình Hồi quy tuyến tính có thể được sử dụng trong một số trường hợp đơn giản, nhưng khả năng dự đoán của nó không mạnh bằng Random Forest.

Hồi quy tuyến tính giả định mối quan hệ tuyến tính giữa các biến, nên dễ dẫn đến sai số lớn khi dữ liệu phi tuyến hoặc biến động cao. Với MAE: 1.38, MSE: 4.26, RMSE: 2.06, và R^2: 0.59, mô hình không phản ánh chính xác các hệ thống phức tạp như chất lượng nước. Vì vậy, đây không phải lựa chọn tối ưu cho các ứng dụng yêu cầu độ chính xác cao và xử lý quan hệ phức tạp.

Gradient Boosting đạt hiệu suất xuất sắc trong dự đoán chất lượng nước với sai số thấp (MSE: 0.11, RMSE: 0.33, MAE: 0.18) và độ chính xác cao (R^2: 0.99). Mô hình gần như hoàn hảo trong việc giải thích 99% sự biến thiên dữ liệu, phản ánh rõ các mối quan hệ phức tạp giữa các yếu tố đầu vào và chất lượng nước.

Vì vậy, trong bối cảnh dự đoán chất lượng nước này, ba mô hình được áp dụng trong việc dự đoán chất lượng nước đều có những đặc điểm và hiệu suất riêng biệt. Gradient

Boosting là mô hình nổi bật hơn với khả năng cung cấp các dự đoán chính xác và giải thích sự biến thiên trong dữ liệu rất tốt, đặc biệt là khi xử lý các mối quan hệ phức tạp. Random Forest cũng là một lựa chọn mạnh mẽ với khả năng linh hoạt trong việc học các đặc điểm phi tuyến và biến động trong dữ liệu, nhưng đôi khi không thể đạt được độ chính xác cao như Gradient Boosting.

KẾT LUẬN VÀ ĐỀ XUẤT HƯỚNG PHÁT TRIỂN

1. Kết quả đạt được

Sau thời gian nghiêm túc thực hiện và nghiên cứu đề tài "Dự đoán chất lượng nước sử dụng học máy," em đã đạt được những kết quả nổi bật, cụ thể như sau:

Em đã nghiên cứu và nắm vững các kỹ thuật học máy, từ Hồi quy tuyến tính đến các mô hình phức tạp như Random Forest và Gradient Boosting. Em cũng làm chủ các kỹ thuật xử lý dữ liệu như làm sạch, xử lý giá trị thiếu và phân tích dữ liệu khám phá (EDA). Đặc biệt, em đã áp dụng các tiêu chí đánh giá mô hình như MSE, MAE, RMSE và R-squared để tối ưu hóa các mô hình học máy trong bài toán dự đoán chất lượng nước.

Trong ứng dụng thực tiễn, em đã xây dựng hai mô hình Hồi quy tuyến tính và Random Forest để dự đoán chất lượng nước, với Random Forest đạt độ chính xác cao hơn nhờ khả năng xử lý mối quan hệ phi tuyến. Em đã phân tích tầm quan trọng của các yếu tố đầu vào và đưa ra khuyến nghị cải thiện chất lượng nước. Hệ thống dự đoán cũng có tiềm năng hỗ trợ giám sát chất lượng nước và phát hiện sớm nguy cơ ô nhiễm.

Kết quả nghiên cứu chứng minh tính ứng dụng của học máy trong giải quyết vấn đề môi trường, đặc biệt là ô nhiễm nguồn nước. Những bài học trong việc xử lý dữ liệu, tối ưu mô hình sẽ giúp em phát triển các ứng dụng công nghệ mới trong tương lai, đóng góp vào bảo vệ môi trường và phát triển bền vững.

2. Hạn chế

Dù đã nỗ lực trong suốt quá trình thực hiện đồ án, em nhận thấy vẫn còn nhiều thiếu sót, chủ yếu xuất phát từ hạn chế kinh nghiệm và kiến thức chuyên sâu trong lĩnh vực học máy. Các mô hình học máy yêu cầu một lượng lớn dữ liệu chất lượng cao để có thể tối ưu hóa và đưa ra dự đoán chính xác. Nếu dữ liệu đầu vào không đầy đủ hoặc bị nhiễu, mô hình sẽ gặp khó khăn trong việc xử lý và đưa ra kết quả đúng đắn. Mặc dù Random Forest và Gradient Boosting có khả năng xử lý mối quan hệ phi tuyến tốt, nhưng chúng cũng có thể gặp phải vấn đề quá khớp (overfitting) nếu không được điều chỉnh siêu tham số một cách cẩn thận.

Ngoài ra, các phương pháp đánh giá hiệu quả thuật toán chủ yếu dựa trên các chỉ số cơ bản (MSE, RMSE, MAE, R-squared), chưa mở rộng đến các kỹ thuật đánh giá chuyên sâu hoặc kiểm tra tính ổn định và tổng quát hóa của mô hình. Quy trình tối ưu tham số chưa sử dụng các kỹ thuật tiên tiến hơn như Random Search hoặc Bayesian Optimization.

Em nhận thấy cần cải thiện khả năng tư duy sáng tạo, nghiên cứu các thuật toán mới và các công cụ hiện đại hơn để đạt được các kết quả mang tính đột phá. Đồng thời, việc áp dụng thêm các phương pháp đánh giá và tối ưu hóa nâng cao sẽ giúp cải thiện hiệu quả của mô hình, góp phần ứng dụng tốt hơn trong các bài toán thực tế.

3. Phương hướng phát triển

Để khắc phục những hạn chế trong quá trình thực hiện đồ án, em sẽ tập trung vào một số phương hướng phát triển quan trọng. Đầu tiên, em sẽ cải thiện chất lượng dữ liệu đầu vào bằng cách tìm kiếm và thu thập dữ liệu chất lượng cao hơn, đồng thời áp dụng các phương pháp xử lý dữ liệu mạnh mẽ để giảm nhiễu và xử lý giá trị thiếu. Thứ hai, để giảm thiểu hiện tượng overfitting, em sẽ nghiên cứu và áp dụng các kỹ thuật điều chỉnh mô hình như cross-validation và regularization, cũng như thử nghiệm với các phương pháp ensemble nâng cao hoặc deep learning. Thứ ba, em sẽ mở rộng các chỉ số đánh giá mô hình, bổ sung các chỉ số như AUC-ROC, precision, recall và F1-score để đánh giá mô hình toàn diện hơn, đồng thời kiểm tra tính ổn định và tổng quát hóa của mô hình qua các bộ dữ liệu khác nhau. Em cũng sẽ nghiên cứu các phương pháp tối ưu hóa siêu tham số tiên tiến như Random Search và Bayesian Optimization để tối ưu hóa hiệu quả mô hình. Cuối cùng, em sẽ nâng cao khả năng tư duy sáng tạo và nghiên cứu thuật toán mới, cũng như học hỏi thêm các công cụ hiện đại như deep learning và reinforcement learning. Những phương hướng này sẽ giúp em cải thiện chất lượng mô hình và tăng cường khả năng áp dụng học máy vào các bài toán thực tiễn.

TÀI LIỆU THAM KHẢO

[1] "Quyết định số: QĐ 1460/QĐ-TCMT Ban hành ngày 12 tháng 11 năm 2019 về Hướng dẫn kỹ thuật tính toán và công bố chỉ số chất lượng nước của Việt Nam (VN_WQI)," 2019.

[2] Bui Tien Tung, "Gradient Boosting - Tất tần tật về thuật toán mạnh mẽ nhất trong Machine Learning," [Online]. Available: https://viblo.asia/p/gradient-boosting-tat-tan-tat-ve-thuat-toan-manh-me-nhat-trong-machine-learning-YWOZrN7vZQ0. [Accessed 9 9 2024].

[3] GeeksforGeeks, "Random Forest Algorithm in Machine Learning," [Online]. Available: https://www.geeksforgeeks.org/random-forest-algorithm-in-machine-learning. [Accessed 10 9 2024].

[4] Bui Quoc Lap, Thi-Thu-Hong Phan, Huu Du Nguyen, Le Xuan Quang, Phi Thi Hang, Nguyen Quang Phi, Vinh Truong Hoang, Pham Gia Linh, Bui Thi Thanh Hang, "Predicting Water Quality Index (WQI) by feature selection and machine learning: A case study of An Kim Hai irrigation system," 2023. [Online]. Available: https://www.sciencedirect.com/science/article/abs/pii/S1574954123000201?via%3Dihub. [Accessed 9 9 2024].

[5] L. BREIMAN, "Random Forests," 2001. [Online]. Available: https://link.springer.com/article/10.1023/A:1010933404324. [Accessed 10 9 2024].

[6] Nguyễn Đức Phong, Hà Hải Dương, "Nghiên cứu ứng dụng các mô hình học máy để dự báo chỉ số chất lượng nước mặt vùng bán đảo Cà Mau," 2023.

[7] Md Galal Uddin, Stephen Nash, Azizur Rahman, Agnieszka I. Olbert , "A sophisticated model for rating water quality," 10 4 2023. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0048969723002292. [Accessed 13 9 2024].

[8] Trevor Hastie , Robert Tibshirani , Jerome Friedman, "The Elements of Statistical Learning," 2009. [Online]. Available: https://www.sas.upenn.edu/~fdiebold/NoHesitations/BookAdvanced.pdf. [Accessed 15 9 2024].

[9] Huỳnh Phú, , Trần Thị Minh Hà, Nguyễn Thị Huệ, "Nghiên cứu đánh giá chất lượng nước các sông chính tỉnh Bình Thuận và đề xuất các giải pháp tiền đề bảo vệ nguồn nước," Tạp chí Khí tượng Thuỷ văn, 2024.